Chiang Mai PM2.5: prediction, evidence and decisions

SUPHANATTHAKON THOBSRI | Student ID: 690631023

270702 Data Science Programming | 24 October 2026 | Four notebooks, twelve settings

1 Problem background

- Fine particulate pollution is associated with respiratory and cardiovascular disease; children are a particularly affected group [1]. A school needs lead time to review outdoor activities and communicate with families. A useful forecast requires timely inputs as well as accuracy.

- Chiang Mai source-apportionment research identifies biomass burning as important during haze periods [2]. This motivates a regional fire predictor, but does not guarantee incremental forecast skill.

- This lab examines severity, timing, tomorrow prediction and an actionable recommendation for one Chiang Mai receptor. Modeled CAMS values are distinguished from measured station exposure throughout.

Study contract

Item	Definition
Location	18.7883 N, 98.9853 E; one receptor
Study targets	2024-01-01 to 2025-12-31; earlier source days are buffers
Issue / target	D 07:00 Thailand -> modeled daily profile P(D+1), local 00:00-24:00
Fixed threshold	37.5 ug/m3; modeled exceedance, not an official measured violation
Scope	Nominal-source-clock-constrained retrospective benchmark; actual original publication/revision not certified

Key findings: baseline first

- The common modeling cohort has 687 of 731 target dates. Test covers all 365 days of calendar 2025.

- Persistence test MAE is 6.282; direct CAMS reference MAE is 3.739. Validation selects H1_3d, whose test MAE is 6.137.

- Selected-model missed exceedances: 23/30; false alerts: 8. Accuracy and operational readiness are separate conclusions.

Evidence: model_scores.csv; selection.json; coverage_summary.json; source_time_contract.json.

2 Approach | questions and expected contributions

Question: what do weather and regional fire histories add beyond PM history, and does a 3-, 5- or 7-day history help? All settings use the same dates and fixed target definition.

Group	Inputs	Paired question at each k	Features: 3 / 5 / 7
H1	PM	H1 - persistence	9 / 15 / 21
H2	PM + weather	H2 - H1	30 / 50 / 70
H3	PM + fire	H3 - H1	15 / 25 / 35
H4	PM + weather + fire	H4 - H2; H4 - H3	36 / 60 / 84

- Subquestions a/b/c mean k=3/5/7. PM persistence motivates H1; meteorological transport/removal motivates H2; biomass-burning activity motivates H3. H4 tests each addition conditionally. Expectations are working hypotheses, not required positive findings.

- A short window may follow recent conditions; a longer one may capture persistence but adds correlated inputs. Validation selects windows, while all three test results remain visible.

Development from the original model

Initial approach	Current approach
Baselines and temporal evaluation already existed	Baselines are retained; source clocks and label maturity are explicit.
Original code used several lags and rolling windows	Compare exactly 3/5/7 days within each of four source groups.
Covered-day zeros and unknown fire days were distinguished	Native GFAS values are distinguished from missing data, with separate QC.
Metrics and configurations were exported	Receipts link sources, data and models; prediction and SQL checks are reproducible.

- Structural progress is clearer timing, provenance and matched comparisons. Better accuracy must be demonstrated separately. The original H1-H4 had different fire-specific meanings; the labels have different meanings in the initial and current experiments.

Evidence: reference/model_development_trace.csv; original_notebook_inventory.json; Appendix F.

3 Method | workflow and information separation

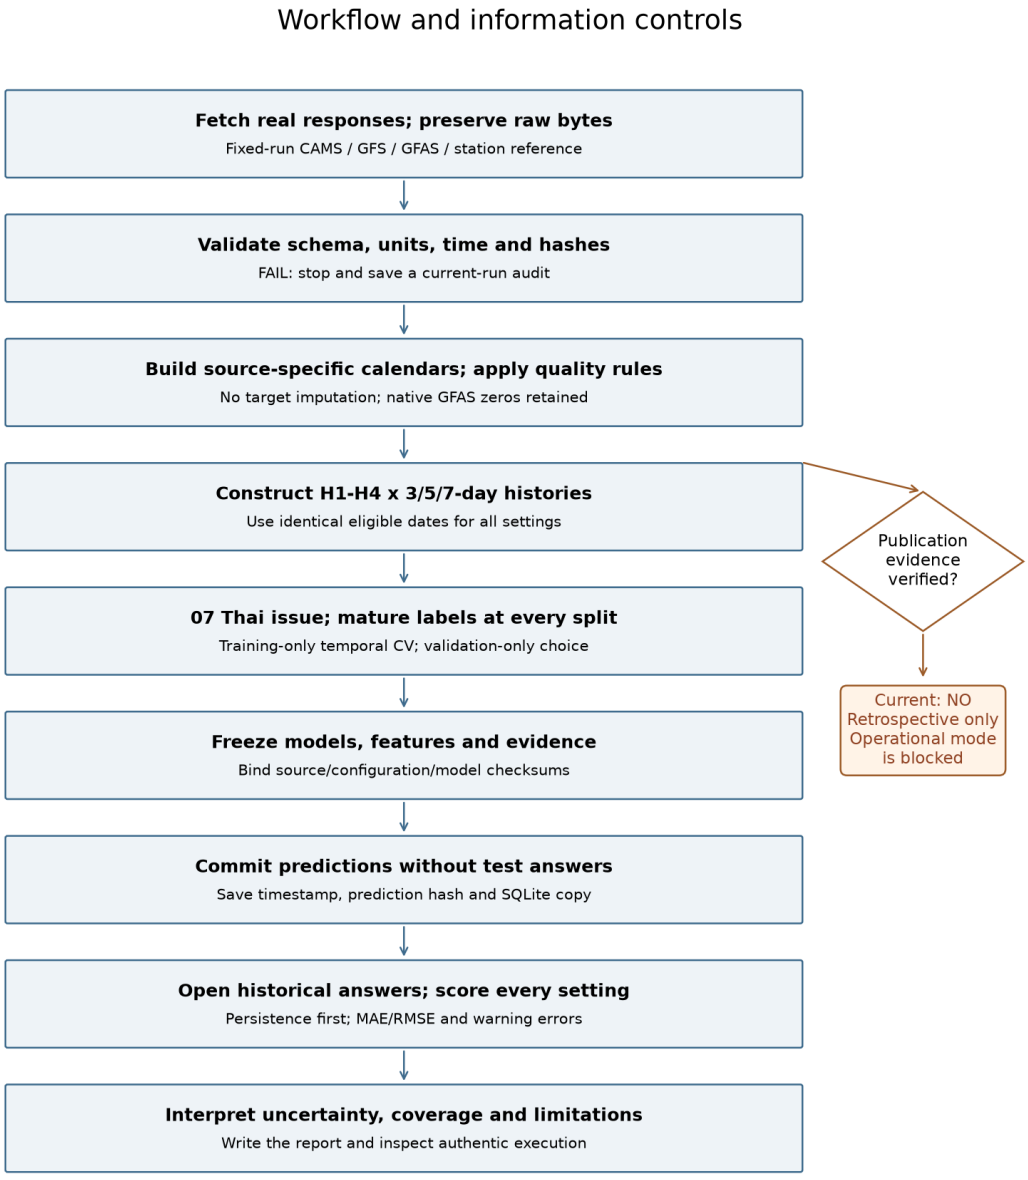


Figure 1. Shared notebook/script workflow. The availability branch keeps operational prediction blocked; technical checks are not original-release evidence.

- Freeze -> commit predictions without test answers -> open answers and score. The SQL store preserves real records and receipts; it is not an independent ground-truth dataset.

- This historical dataset was previously inspected. Interface isolation does not turn it into an untouched or prospective trial.

3 Method | sources, target and time availability

Source / role	Native product and clock	At issue D 07:00 Thailand
PM history / target	ADS CAMS mc/fc/0001; run d-1 at 12 UTC; leads 5-28 form P(d)	History P(D-1)..P(D-k). Target P(D+1) is later verification output.
Weather history	Open-Meteo gfs_global previous_day1 forecast values; local daily summaries	Days D-1..D-k. Fixed forecast offset is not an observed public-release timestamp.
Fire history	GFAS v1.2 daily UTC means; FRP density and observation-opportunity QC	UTC days D-2..D-(k+1), reflecting the documented next-day 07 UTC schedule.
Provider reference	CAMS run D-1 at 12 UTC, leads 29-52	Target D+1, nominally released 2h before issue; never a learned feature.

API / dataset	Request identity
ADS /api	https://ads.atmosphere.copernicus.eu/api; datasets: cams-global-atmospheric-composition-forecasts and cams-global-fire-emissions-gfas.
Public weather /v1/forecast	https://previous-runs-api.open-meteo.com/v1/forecast; models=gfs_global, six *_previous_day1 fields, timezone=UTC, wind_speed_unit=ms.
Request periods	PM runs: 2023-12-23..2025-12-30; GFAS UTC days: 2023-12-23..2025-12-31; weather UTC hours: 2024-01-01..2025-12-31. Exact bounds/areas are preserved in raw plans and manifests.

Explicit clock example

- For issue 1 January 2025 at 07:00 Thailand (=00 UTC), predict 2 January local 00:00-24:00. Target starts 17h and ends 41h after issue. The PM/weather 7-day history is 25-31 December; GFAS UTC history is 24-30 December.

- CAMS 12 UTC is scheduled by 22 UTC; GFAS daily analysis by 07 UTC. Latest PM history has 26h nominal margin, fire 17h, and provider reference 2h. ADS delivery exceptions remain possible [3,4].

- Section 6.2: source-day and target offsets are checked; labels must mature before evaluation and transforms fit within training folds. Documented source clocks inform the offsets. Exact historical public-release/revision was not audited, so operational replay is not certified.

Evidence: source_time_contract.json; raw transfer_receipt.json; timezone_examples.csv; study_contract.json.

3 Method | preparation and row reconciliation C1-C3

C1-C2: preserve calendars, units and one-to-one joins

Step	Rows / decision
Study target calendar	731 days across full 2024-2025
Value-complete PM/fire/weather 7-day histories	704; first usable target 28 January 2024
Declared source-advisory dependency quarantine	15 targets: 9-23 August 2024; conservative, not confirmed local contamination
Outer label-maturity purges	30 September and 31 December 2024: 2 days
Common modeling cohort	687 days shared by all 12 settings

- The table keeps history buffers before the study and unavailable targets after it. PM/weather join on local dates; GFAS on its explicit earlier UTC mean day. Calendar lags precede exclusions, so missing dates cannot become adjacent observations.

Source before join	Alignment / retained calendar
739 complete PM profiles	One local profile per date; 739 history-anchor calendar rows.
17544 weather UTC hours	Convert to Thai time; require 24 valid hours per daily field; missing values remain missing.
740 GFAS UTC days (two fields/day)	Latest source day D-2; reindex to the 739-row history calendar.
Calendar before / after join	739 / 739; one-to-one keys, no row multiplication. Buffers and out-of-study targets stay in the ledger.

C3: fill/drop decisions and native zeros

- No target or predictor interpolation, forward fill, median replacement or blanket zero filling. Daily PM/weather need 24 valid hours. Missing or invalid input makes its complete-history row ineligible; raw records remain preserved.

- GFAS native regional FRP is all zero on 323 of 740 captured UTC days; the longest run is 59 days, 11 June-8 August 2025. These are source-analysis values, not project-imputed missing. They do not prove absence of real fires; assimilation and observation opportunity remain source limitations.

- GFAS density (W/m2) is integrated with spherical cell area: mean power MW = sum(density*area)/1e6.
Positive-analysis area fraction is an extent index, not hotspots or burnt area. offire may exceed 1 and is not clipped or modeled [4].

Evidence: join_audit.json; row_inclusion.csv; missing_decisions.csv; gfas_daily_derived.csv; fire_area_aggregation.json.

3 Method | variables, models and evaluation

Input group	Base variables and units
PM:3	Mean / minimum / maximum of the same 24-hour profile (ug/m3)
Weather:7	Temperature(degC), humidity(%), pressure(hPa), wind speed/u/v(m/s), precipitation total(mm/day)
Fire:2	log1p(area-integrated mean FRP in MW); positive-analysis area fraction
Excluded	Target, dates, quality/availability flags, offire and provider reference are not learned predictors

- Hourly wind components u=-s*sin(theta), v=-s*cos(theta) are averaged after conversion. Rain intervals use their start day. A k-day setting has only its source groups and lags 0..k-1; its actual source days follow the source-clock contract.

- Primary Ridge: squared error plus alpha*sum(beta squared), alpha in {0.1,1,10,100,1000}; StandardScaler fits only within training folds. HGB is secondary: 200 iterations, learning rate 0.05,minimum leaf 20; leaf nodes 7/15 and L2=0/10. Both clip predictions at 0 consistently in CV and scoring.

Partition	Dates	N
train	2024-01-28 to 2024-09-29	231
validation	2024-10-01 to 2024-12-30	91
test	2025-01-01 to 2025-12-31	365

- Three training-only expanding calendar folds use gap 1 plus explicit label-completion checks. Two outer boundaries are purged before selection/refit, because next-phase first issue precedes completion of those target days.

- Validation MAE selects the primary source/window and within-group preferred windows. Every fixed setting is reported on test; no test winner is promoted. Moving-block 95% intervals: 14 days, 1000 repeats, seed 42; 7/28-day blocks are secondary sensitivity.

Evidence: feature_manifest.csv; cv_calendar_audit.csv; chronology.csv; forecast_lock.json; tuning.json.

4 Results | severity, seasonality and fire quality

Year	Valid days	Mean PM	Maximum	Modeled exceedance days
2024	366	19.55	44.62	10
2025	365	23.77	91.88	30

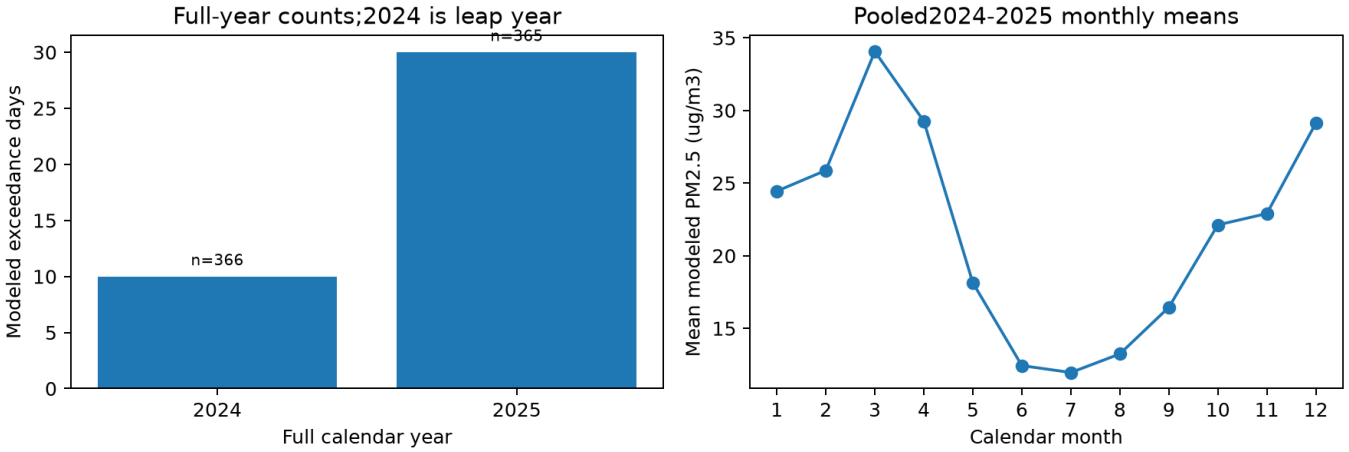


Figure 2. Full-year modeled counts with actual denominators;2024 includes leap day. Pooled monthly means describe two archived model years, not a long-term measured trend.

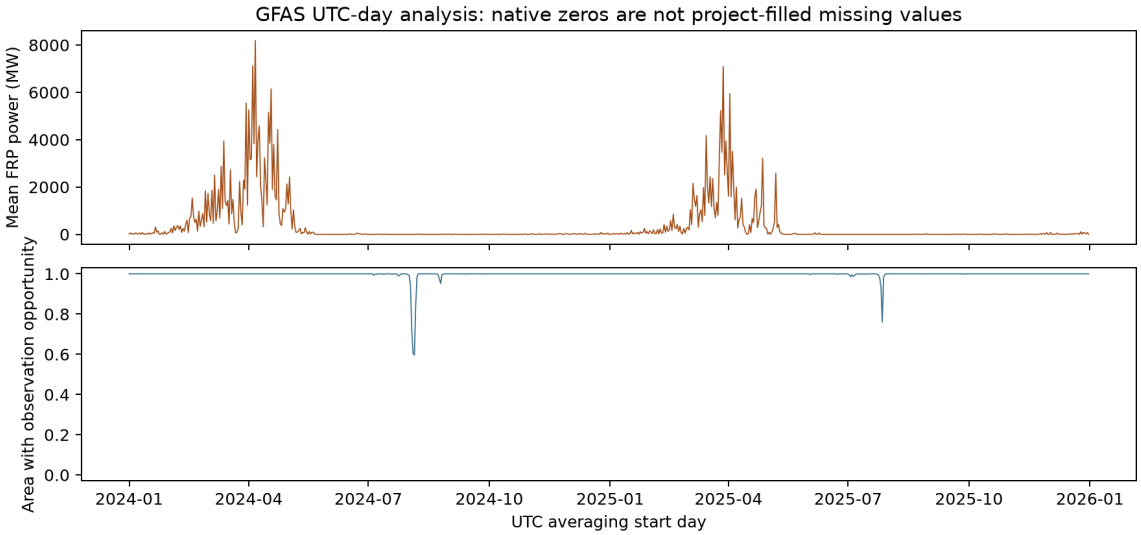


Figure 3. GFAS mean FRP power and observation-opportunity area are different quantities. Native zero-analysis stretches are retained; no detection/observation completeness claim follows.

- Severity uses the full modeled calendar; predictive scores below use the common cohort and declared partitions. These populations are not interchangeable.

Evidence: annual_summary.csv; monthly_summary.csv; coverage_by_month.csv; gfas_daily_derived.csv.

4 Results | baseline first, then all twelve settings C5

Test reference	MAE	RMSE	Recall	FP / FN
B0_persistence	6.282	8.766	0.367	19 / 19
B1_provider_forecast	3.739	5.195	0.667	25 / 10
C0_training_majority	-	-	0.000	0 / 30

Primary Ridge setting	MAE	RMSE	Recall	FP / FN
H1_3d	6.137	8.512	0.233	8 / 23
H1_5d	6.236	8.619	0.200	11 / 24
H1_7d	6.585	8.983	0.267	13 / 22
H2_3d	5.701	8.112	0.200	4 / 24
H2_5d	5.705	8.010	0.200	3 / 24
H2_7d	5.792	8.252	0.133	3 / 26
H3_3d	6.105	8.391	0.400	11 / 18
H3_5d	5.796	7.929	0.300	11 / 21
H3_7d	6.284	8.550	0.467	15 / 16
H4_3d	5.741	8.023	0.233	5 / 23
H4_5d	5.754	7.950	0.233	6 / 23
H4_7d	5.755	8.171	0.133	3 / 26

- Validation selected H1_3d; its test MAE is 6.137. Relative to persistence this is 2.3% lower. Relative to the provider forecast it is 64.1% higher.

- All rows use identical 365 test dates. C0 is warning-only; its numeric encoding is not assigned a regression score. A good persistence comparison alone does not show benefit over the earlier CAMS forecast.

Evidence: model_scores.csv; predictions_test.csv; selection.json; metrics.csv. Secondary HGB results appear in Appendix C.

4 Results | incremental inputs and uncertainty

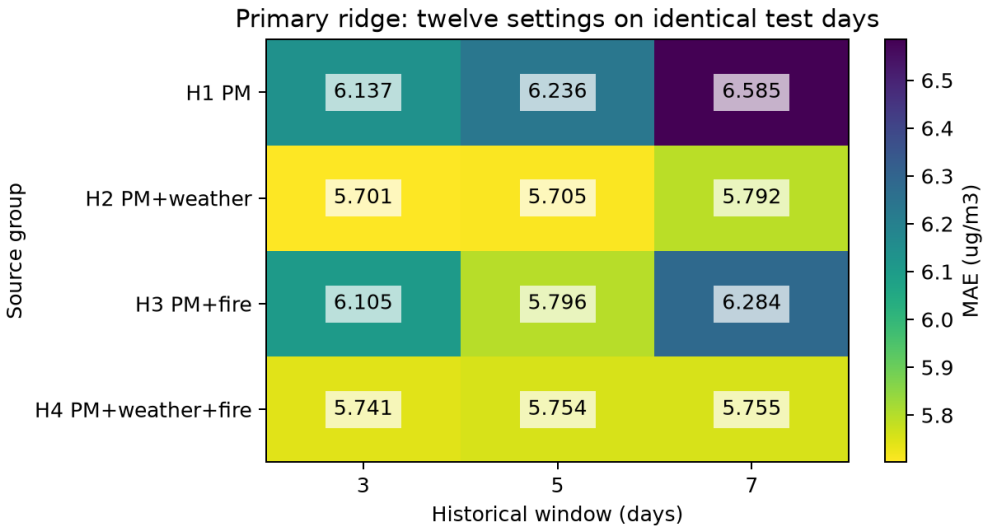


Figure 4. All 12 primary settings on matched dates. Color/rank does not change the validation-selected candidate.

k	Increment	MAE difference	Pointwise 95% block interval
3	H1-B0	-0.145	[-0.528, +0.238]
3	H2-H1	-0.435	[-0.761, -0.159]
3	H3-H1	-0.031	[-0.252, +0.155]
3	H4-H2	+0.040	[-0.070, +0.148]
3	H4-H3	-0.364	[-0.817, +0.068]
5	H1-B0	-0.046	[-0.430, +0.357]
5	H2-H1	-0.531	[-0.913, -0.214]
5	H3-H1	-0.440	[-0.693, -0.236]
5	H4-H2	+0.049	[-0.078, +0.172]
5	H4-H3	-0.042	[-0.376, +0.264]
7	H1-B0	+0.303	[-0.189, +0.896]
7	H2-H1	-0.794	[-1.614, -0.127]
7	H3-H1	-0.301	[-0.583, -0.056]
7	H4-H2	-0.036	[-0.116, +0.022]
7	H4-H3	-0.528	[-1.401, +0.236]

- Negative differences favor the added group. Intervals spanning 0 are inconclusive; intervals entirely above 0 favor the reference. H4 needs both conditional comparisons to distinguish weather from fire contributions.

- Across 7/14/28-day block sensitivity, 1 of 15 primary contrast classifications change. These are exploratory pointwise intervals, not multiplicity-adjusted confirmations; uncertainty is not hidden when a working expectation fails.

Evidence: paired_comparisons.csv; twelve_answers.csv; bootstrap_sensitivity.csv; window_selection_by_group.csv.

4 Results | warning errors and station reference C4-C6

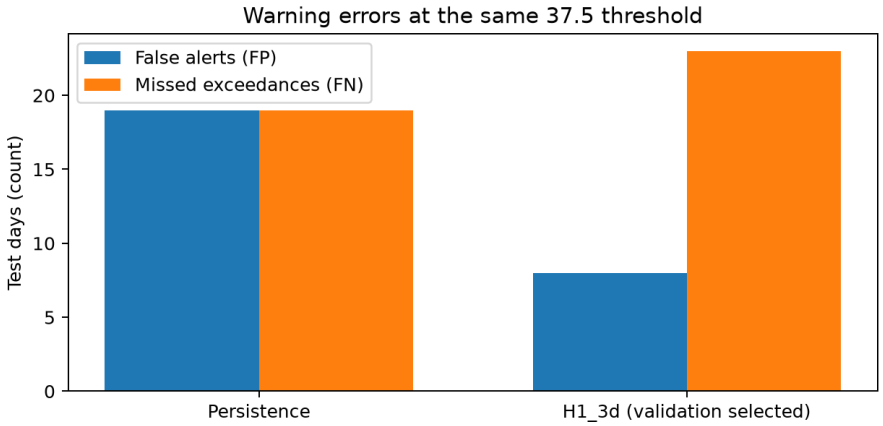


Figure 5. Fixed 37.5 threshold on the same modeled test outcomes; lower MAE does not guarantee fewer missed exceedances.

- Selected model: recall 0.233, precision 0.467, FP 8, FN 23. Persistence: FP 19, FN 19. Provider reference: FP 25, FN 10.

C4: one primary receptor, explicit source grids

- The requested Chiang Mai receptor maps to ADS 18.8N, 98.8E on 0.4-degree output. Weather has its own source grid; the regional fire box is not another PM location. No second independent study site is invented.

C6: preserved contemporary measured reference

Station	Reporting local time	Air4Thai 24h	CAMS 24 samples	Signed difference
36t	2026-10-16T21:00:00	13.30	12.97	-0.33
35t	2026-10-16T21:00:00	16.40	12.97	-3.43

- This 16 October 2026 station/Open-Meteo snapshot is outside the 2024-2025 study and uses a separate product/grid. Air4Thai rolling 24h concentration is compared with 24 modeled hourly samples at nominally matched location/time; one-hour boundary sensitivity is retained. It does not validate the historical ADS target [6].

- Subject to station QA, the ground monitor is the local empirical reference; CAMS is a coarse-grid model product. Differences may reflect grid and averaging-window mismatch; this point check does not validate historical ADS targets or station-level warning skill.

Evidence: station_crosscheck.csv/json; spatial_resolution_audit.json; warning_day_details.csv; missed_day_details.csv.

5 Conclusion | supported actions and limitations

The direct answer is conditional on the modeled target and retained dates: validation chose H1_3d. Its MAE is 6.137, persistence 6.282, provider reference 3.739. Warning misses are 23 vs 19 and 10, respectively. Source additions and window answers are reported separately, not reduced to one winner.

Incremental answers (pointwise intervals): H1 beats persistence with an interval below 0 at k=none. Weather beyond PM is supported at k=3/5/7; fire beyond PM at k=5/7. Fire conditional on weather: k=none; weather conditional on fire: k=none. These are exploratory associations, not causal or familywise-confirmed effects.

What improved structurally, and what the numbers establish

- The original already had baselines, temporal evaluation and multiple lags. The current design improves the inspectable contract: fixed archived vintages, actual 07:00 next-day horizon, source-specific offsets, cell-area-correct fire variables, label-maturity purges and current-run provenance.

- Predictive improvement is assessed against contemporaneous baselines on matched dates. Old/new MAE also changes with product, horizon, period and cohort; it cannot isolate algorithm improvement. Appendix F preserves both results and explains this comparison limit.

- Training/validation contain 7/3 modeled exceedances, versus 30 in test. The validation-selected candidate is not the lowest-test-MAE setting; this shift and the short validation season limit generalization. These counts explain uncertainty, not a reason to retune the inspected test.

Who should do what, and when

Owner / timing	Proposed action and check
Principal / before outdoor activities	Review current official local air-quality information under existing school policy; log source/time and the decision. Recheck when conditions change. Do not treat this prototype as an automatic warning.
Analytics team / each 07:00 trial issue	Shadow trial only: retain source values/versions, acquisition times, issued prediction and missing-input status; do not backfill a missed issue. Score later against a separately defined local measured target.
School + analytics / before trial and review	Agree FN/FP costs, minimum acceptable recall, review schedule and stop conditions before seeing new outcomes. Compare persistence and direct-provider forecasts; a failed source gate means no automatic release.

- These are proposed procedures, not evidence that a school adopted them. For the current modeled test, cost=FP+r*FN gives selected-minus-persistence = -11+4r; selected is worse for r>2.75. The cost ratio is illustrative, not a measured stakeholder value. False reassurance and unnecessary disruption require explicit review.

Limits that remain open

- Temporal cutoff and label-maturity checks address Section 6.2 under this retrospective design. Separate limits remain: exact historical public release/revision, one coarse-grid receptor, GFAS/CAMS source dependence, two-year/model-cycle variability and exploratory multiple comparisons.

Evidence: availability_gate.json; source_time_contract.json; model_development_comparison.csv; reference_store.json. Student review/signature and actual repository/video submission remain external tasks.

Appendix A | every-column missingness and decisions

Denominators include all 739 daily history-anchor rows, with explicit buffers and out-of-study targets. Raw native source missingness and derived-calendar missingness are different quantities.

Column	Missing N	Total N	Missing %
date	0	739	0.000
pm25_mean	0	739	0.000
pm25_min	0	739	0.000
pm25_max	0	739	0.000
pm25_valid_hours	0	739	0.000
temperature_mean	27	739	3.654
humidity_mean	27	739	3.654
pressure_mean	27	739	3.654
wind_speed_ms	27	739	3.654
wind_u_ms	27	739	3.654
wind_v_ms	27	739	3.654
precipitation_sum	27	739	3.654
rain_valid_hours	8	739	1.083
weather_min_valid_hours	8	739	1.083
fire_power_mw	0	739	0.000
log_fire_power_mw	0	739	0.000
fire_positive_area_fraction	0	739	0.000
fire_observation_area_fraction	0	739	0.000
fire_opportunity_weighted_mean	0	739	0.000
fire_zero_grid_cells	0	739	0.000
fire_missing_grid_cells	0	739	0.000
fire_project_fill_applied	0	739	0.000
fire_source_day_utc	0	739	0.000
target_date	0	739	0.000
issue_date	0	739	0.000
forecast_origin_utc	0	739	0.000
target_complete_utc	0	739	0.000
pm25_tomorrow	2	739	0.271
exceed_tomorrow	2	739	0.271
provider_forecast	1	739	0.135
source_advisory_dependency	0	739	0.000
in_study_target_calendar	0	739	0.000
outer_label_purge	0	739	0.000

Column	Action / reason
date	Retain audit identity/QC; exclude it from learned features. History anchor D-1; calendar join key, not a predictor.
pm25_mean	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
pm25_min	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
pm25_max	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
pm25_valid_hours	Retain audit identity/QC; exclude it from learned features. Number of valid PM samples; 24 required.
temperature_mean	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
humidity_mean	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.

Column	Action / reason
pressure_mean	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
wind_speed_ms	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
wind_u_ms	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
wind_v_ms	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
precipitation_sum	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
rain_valid_hours	Retain audit identity/QC; exclude it from learned features. Valid precipitation intervals in the local day; 24 required.
weather_min_valid_hours	Retain audit identity/QC; exclude it from learned features. Minimum valid count across hourly weather fields.
fire_power_mw	Retain audit identity/QC; exclude it from learned features. Area-integrated daily mean FRP power before log1p; not energy or emissions.
log_fire_power_mw	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
fire_positive_area_fraction	No imputation; preserve missing and require complete calendar windows. Avoid invented history or target-dependent eligibility. Native GFAS zeros are retained, not filled.
fire_observation_area_fraction	Retain audit identity/QC; exclude it from learned features. Area fraction with native offire > 0; observation-opportunity QC, not burnt area.
fire_opportunity_weighted_mean	Retain audit identity/QC; exclude it from learned features. Area-weighted native offire QC; values above 1 are retained.
fire_zero_grid_cells	Retain audit identity/QC; exclude it from learned features. Number of cells with zero native FRP analysis.
fire_missing_grid_cells	Retain audit identity/QC; exclude it from learned features. Number of missing native fire cells; missing fields are rejected.
fire_project_fill_applied	Retain audit identity/QC; exclude it from learned features. Whether the project filled fire values; false in this study.
fire_source_day_utc	Retain audit identity/QC; exclude it from learned features. Start date of the GFAS UTC daily averaging interval.
target_date	Retain audit identity/QC; exclude it from learned features. Forecast verification day D+1; not a predictor.
issue_date	Retain audit identity/QC; exclude it from learned features. Issue day D; issue time is 07:00 Thailand.
forecast_origin_utc	Retain audit identity/QC; exclude it from learned features. Timezone-aware forecast issue instant.
target_complete_utc	Retain audit identity/QC; exclude it from learned features. End of the target local day; used to check label maturity.
pm25_tomorrow	No target fill; require the exact next-day-after-issue profile. Unknown outcomes cannot become safe labels.
exceed_tomorrow	No target fill; require the exact next-day-after-issue profile. Unknown outcomes cannot become safe labels.
provider_forecast	Retain baseline; no imputation; require a present reference on common dates. Compare every baseline and setting on identical dates; never use B1 as a learned feature.
source_advisory_dependency	Retain audit identity/QC; exclude it from learned features. Target or history intersects the prespecified advisory dependency mask.
in_study_target_calendar	Retain audit identity/QC; exclude it from learned features. Target date falls within the declared study period.
outer_label_purge	Retain audit identity/QC; exclude it from learned features. Boundary target excluded because its label is not mature at the next phase.

Appendix A | daily variables, units and retain/drop rationale

Column	Unit	Purpose	Input?
date	local date	History anchor D-1; calendar join key, not a predictor.	False
pm25_mean	ug/m3	Fixed-vintage mean of 24 instantaneous CAMS hourly values.	True
pm25_min	ug/m3	Minimum of the same admitted daily forecast profile.	True
pm25_max	ug/m3	Maximum of the same admitted daily forecast profile.	True
pm25_valid_hours	hourly values (count)	Number of valid PM samples; 24 required.	False
temperature_mean	deg C	Mean 2 m temperature from GFS previous_day1 forecast history.	True
humidity_mean	%	Mean 2 m relative humidity; association rather than causal evidence.	True
pressure_mean	hPa	Mean forecast surface pressure.	True
wind_speed_ms	m/s	Arithmetic mean hourly 10 m wind speed.	True
wind_u_ms	m/s	Mean eastward component derived before aggregation.	True
wind_v_ms	m/s	Mean northward component derived before aggregation.	True
precipitation_sum	mm/day	Sum of preceding-hour intervals assigned to interval-start local day.	True
rain_valid_hours	hourly values (count)	Valid precipitation intervals in the local day; 24 required.	False
weather_min_valid_hours	hourly values (count)	Minimum valid count across hourly weather fields.	False
fire_power_mw	MW	Area-integrated daily mean FRP power before log1p; not energy or emissions.	False
log_fire_power_mw	log1p(MW-valued index)	Log1p of area-integrated daily-mean GFAS FRP power; not energy/emissions.	True
fire_positive_area_fraction	fraction of bounding-box grid area	Area fraction with strictly positive GFAS analysis density; not hotspots or burnt area.	True
fire_observation_area_fraction	dimensionless fraction	Area fraction with native offire > 0; observation-opportunity QC, not burnt area.	False
fire_opportunity_weighted_mean	dimensionless index	Area-weighted native offire QC; values above 1 are retained.	False
fire_zero_grid_cells	grid cells (count)	Number of cells with zero native FRP analysis.	False
fire_missing_grid_cells	grid cells (count)	Number of missing native fire cells; missing fields are rejected.	False
fire_project_fill_applied	boolean	Whether the project filled fire values; false in this study.	False
fire_source_day_utc	UTC date	Start date of the GFAS UTC daily averaging interval.	False
target_date	local date	Forecast verification day D+1; not a predictor.	False
issue_date	local date	Issue day D; issue time is 07:00 Thailand.	False
forecast_origin_utc	UTC timestamp	Timezone-aware forecast issue instant.	False
target_complete_utc	UTC timestamp	End of the target local day; used to check label maturity.	False
pm25_tomorrow	ug/m3	Target P(D+1); history anchor+2; never a feature.	False
exceed_tomorrow	binary 0/1	Derived target: PM > 37.5; unknown PM retains a missing label.	False
provider_forecast	ug/m3	Direct CAMS baseline B1 for the target day; never a learned feature.	False
source_advisory_dependency	boolean	Target or history intersects the prespecified advisory dependency mask.	False
in_study_target_calendar	boolean	Target date falls within the declared study period.	False
outer_label_purge	boolean	Boundary target excluded because its label is not mature at the next phase.	False

Appendix B | every derived predictor

Exactly 84 maximum-window predictors. PM/weather lagj uses local day D-1-j; fire uses UTC day D-2-j. Original public release remains unverified; nominal rules are explicit.

Feature	Group	Lag	Unit	Purpose
pm25_mean_lag0	PM	0	ug/m3	Fixed-vintage mean of 24 instantaneous CAMS hourly values.
pm25_mean_lag1	PM	1	ug/m3	Fixed-vintage mean of 24 instantaneous CAMS hourly values.
pm25_mean_lag2	PM	2	ug/m3	Fixed-vintage mean of 24 instantaneous CAMS hourly values.
pm25_mean_lag3	PM	3	ug/m3	Fixed-vintage mean of 24 instantaneous CAMS hourly values.
pm25_mean_lag4	PM	4	ug/m3	Fixed-vintage mean of 24 instantaneous CAMS hourly values.
pm25_mean_lag5	PM	5	ug/m3	Fixed-vintage mean of 24 instantaneous CAMS hourly values.
pm25_mean_lag6	PM	6	ug/m3	Fixed-vintage mean of 24 instantaneous CAMS hourly values.
pm25_min_lag0	PM	0	ug/m3	Minimum of the same admitted daily forecast profile.
pm25_min_lag1	PM	1	ug/m3	Minimum of the same admitted daily forecast profile.
pm25_min_lag2	PM	2	ug/m3	Minimum of the same admitted daily forecast profile.
pm25_min_lag3	PM	3	ug/m3	Minimum of the same admitted daily forecast profile.
pm25_min_lag4	PM	4	ug/m3	Minimum of the same admitted daily forecast profile.
pm25_min_lag5	PM	5	ug/m3	Minimum of the same admitted daily forecast profile.
pm25_min_lag6	PM	6	ug/m3	Minimum of the same admitted daily forecast profile.
pm25_max_lag0	PM	0	ug/m3	Maximum of the same admitted daily forecast profile.
pm25_max_lag1	PM	1	ug/m3	Maximum of the same admitted daily forecast profile.
pm25_max_lag2	PM	2	ug/m3	Maximum of the same admitted daily forecast profile.
pm25_max_lag3	PM	3	ug/m3	Maximum of the same admitted daily forecast profile.
pm25_max_lag4	PM	4	ug/m3	Maximum of the same admitted daily forecast profile.
pm25_max_lag5	PM	5	ug/m3	Maximum of the same admitted daily forecast profile.
pm25_max_lag6	PM	6	ug/m3	Maximum of the same admitted daily forecast profile.
temperature_mean_lag0	weather	0	deg C	Mean 2 m temperature from GFS previous_day1 forecast history.
temperature_mean_lag1	weather	1	deg C	Mean 2 m temperature from GFS previous_day1 forecast history.
temperature_mean_lag2	weather	2	deg C	Mean 2 m temperature from GFS previous_day1 forecast history.
temperature_mean_lag3	weather	3	deg C	Mean 2 m temperature from GFS previous_day1 forecast history.
temperature_mean_lag4	weather	4	deg C	Mean 2 m temperature from GFS previous_day1 forecast history.
temperature_mean_lag5	weather	5	deg C	Mean 2 m temperature from GFS previous_day1 forecast history.
temperature_mean_lag6	weather	6	deg C	Mean 2 m temperature from GFS previous_day1 forecast history.
humidity_mean_lag0	weather	0	%	Mean 2 m relative humidity; association rather than causal evidence.
humidity_mean_lag1	weather	1	%	Mean 2 m relative humidity; association rather than causal evidence.
humidity_mean_lag2	weather	2	%	Mean 2 m relative humidity; association rather than causal evidence.
humidity_mean_lag3	weather	3	%	Mean 2 m relative humidity; association rather than causal evidence.
humidity_mean_lag4	weather	4	%	Mean 2 m relative humidity; association rather than causal evidence.
humidity_mean_lag5	weather	5	%	Mean 2 m relative humidity; association rather than causal evidence.
humidity_mean_lag6	weather	6	%	Mean 2 m relative humidity; association rather than causal evidence.
pressure_mean_lag0	weather	0	hPa	Mean forecast surface pressure.
pressure_mean_lag1	weather	1	hPa	Mean forecast surface pressure.
pressure_mean_lag2	weather	2	hPa	Mean forecast surface pressure.
pressure_mean_lag3	weather	3	hPa	Mean forecast surface pressure.
pressure_mean_lag4	weather	4	hPa	Mean forecast surface pressure.
pressure_mean_lag5	weather	5	hPa	Mean forecast surface pressure.

Feature	Group	Lag	Unit	Purpose
pressure_mean_lag6	weather	6	hPa	Mean forecast surface pressure.
wind_speed_ms_lag0	weather	0	m/s	Arithmetic mean hourly 10 m wind speed.
wind_speed_ms_lag1	weather	1	m/s	Arithmetic mean hourly 10 m wind speed.
wind_speed_ms_lag2	weather	2	m/s	Arithmetic mean hourly 10 m wind speed.
wind_speed_ms_lag3	weather	3	m/s	Arithmetic mean hourly 10 m wind speed.
wind_speed_ms_lag4	weather	4	m/s	Arithmetic mean hourly 10 m wind speed.
wind_speed_ms_lag5	weather	5	m/s	Arithmetic mean hourly 10 m wind speed.
wind_speed_ms_lag6	weather	6	m/s	Arithmetic mean hourly 10 m wind speed.
wind_u_ms_lag0	weather	0	m/s	Mean eastward component derived before aggregation.
wind_u_ms_lag1	weather	1	m/s	Mean eastward component derived before aggregation.
wind_u_ms_lag2	weather	2	m/s	Mean eastward component derived before aggregation.
wind_u_ms_lag3	weather	3	m/s	Mean eastward component derived before aggregation.
wind_u_ms_lag4	weather	4	m/s	Mean eastward component derived before aggregation.
wind_u_ms_lag5	weather	5	m/s	Mean eastward component derived before aggregation.
wind_u_ms_lag6	weather	6	m/s	Mean eastward component derived before aggregation.
wind_v_ms_lag0	weather	0	m/s	Mean northward component derived before aggregation.
wind_v_ms_lag1	weather	1	m/s	Mean northward component derived before aggregation.
wind_v_ms_lag2	weather	2	m/s	Mean northward component derived before aggregation.
wind_v_ms_lag3	weather	3	m/s	Mean northward component derived before aggregation.
wind_v_ms_lag4	weather	4	m/s	Mean northward component derived before aggregation.
wind_v_ms_lag5	weather	5	m/s	Mean northward component derived before aggregation.
wind_v_ms_lag6	weather	6	m/s	Mean northward component derived before aggregation.
precipitation_sum_lag0	weather	0	mm/day	Sum of preceding-hour intervals assigned to interval-start local day.
precipitation_sum_lag1	weather	1	mm/day	Sum of preceding-hour intervals assigned to interval-start local day.
precipitation_sum_lag2	weather	2	mm/day	Sum of preceding-hour intervals assigned to interval-start local day.
precipitation_sum_lag3	weather	3	mm/day	Sum of preceding-hour intervals assigned to interval-start local day.
precipitation_sum_lag4	weather	4	mm/day	Sum of preceding-hour intervals assigned to interval-start local day.
precipitation_sum_lag5	weather	5	mm/day	Sum of preceding-hour intervals assigned to interval-start local day.
precipitation_sum_lag6	weather	6	mm/day	Sum of preceding-hour intervals assigned to interval-start local day.
log_fire_power_mw_lag0	fire	0	log1p(MW-valued index)	Log1p of area-integrated daily-mean GFAS FRP power; not energy/emissions.
log_fire_power_mw_lag1	fire	1	log1p(MW-valued index)	Log1p of area-integrated daily-mean GFAS FRP power; not energy/emissions.
log_fire_power_mw_lag2	fire	2	log1p(MW-valued index)	Log1p of area-integrated daily-mean GFAS FRP power; not energy/emissions.
log_fire_power_mw_lag3	fire	3	log1p(MW-valued index)	Log1p of area-integrated daily-mean GFAS FRP power; not energy/emissions.
log_fire_power_mw_lag4	fire	4	log1p(MW-valued index)	Log1p of area-integrated daily-mean GFAS FRP power; not energy/emissions.
log_fire_power_mw_lag5	fire	5	log1p(MW-valued index)	Log1p of area-integrated daily-mean GFAS FRP power; not energy/emissions.
log_fire_power_mw_lag6	fire	6	log1p(MW-valued index)	Log1p of area-integrated daily-mean GFAS FRP power; not energy/emissions.
fire_positive_area_fraction_lag0	fire	0	fraction of bounding-box grid area	Area fraction with strictly positive GFAS analysis density; not hotspots or burnt area.
fire_positive_area_fraction_lag1	fire	1	fraction of bounding-box grid area	Area fraction with strictly positive GFAS analysis density; not hotspots or burnt area.
fire_positive_area_fraction_lag2	fire	2	fraction of bounding-box grid area	Area fraction with strictly positive GFAS analysis density; not hotspots or burnt area.
fire_positive_area_fraction_lag3	fire	3	fraction of bounding-box grid area	Area fraction with strictly positive GFAS analysis density; not hotspots or burnt area.
fire_positive_area_fraction_lag4	fire	4	fraction of bounding-box grid area	Area fraction with strictly positive GFAS analysis density; not hotspots or burnt area.

Feature	Group	Lag	Unit	Purpose
fire_positive_area_fraction_lag5	fire	5	fraction of bounding-box grid area	Area fraction with strictly positive GFAS analysis density; not hotspots or burnt area.
fire_positive_area_fraction_lag6	fire	6	fraction of bounding-box grid area	Area fraction with strictly positive GFAS analysis density; not hotspots or burnt area.

Appendix C | complete experiment answers and robustness

Learner / setting	MAE	Recall	FP/FN	Answer
ridge / H1_3d	6.137	0.233	8/23	H1-B0: no clear MAE difference; interval spans zero; delta=-0.1453, 95% CI [-0.5277, 0.2377]
ridge / H1_5d	6.236	0.200	11/24	H1-B0: no clear MAE difference; interval spans zero; delta=-0.0463, 95% CI [-0.4300, 0.3573]
ridge / H1_7d	6.585	0.267	13/22	H1-B0: no clear MAE difference; interval spans zero; delta=0.3034, 95% CI [-0.1887, 0.8963]
ridge / H2_3d	5.701	0.200	4/24	H2-H1: lower MAE with pointwise exploratory interval below zero; delta=-0.4352, 95% CI [-0.7614, -0.1585]
ridge / H2_5d	5.705	0.200	3/24	H2-H1: lower MAE with pointwise exploratory interval below zero; delta=-0.5306, 95% CI [-0.9130, -0.2141]
ridge / H2_7d	5.792	0.133	3/26	H2-H1: lower MAE with pointwise exploratory interval below zero; delta=-0.7937, 95% CI [-1.6135, -0.1274]
ridge / H3_3d	6.105	0.400	11/18	H3-H1: no clear MAE difference; interval spans zero; delta=-0.0313, 95% CI [-0.2523, 0.1553]
ridge / H3_5d	5.796	0.300	11/21	H3-H1: lower MAE with pointwise exploratory interval below zero; delta=-0.4399, 95% CI [-0.6930, -0.2359]
ridge / H3_7d	6.284	0.467	15/16	H3-H1: lower MAE with pointwise exploratory interval below zero; delta=-0.3015, 95% CI [-0.5828, -0.0562]
ridge / H4_3d	5.741	0.233	5/23	H4-H2: no clear MAE difference; interval spans zero; delta=0.0397, 95% CI [-0.0697, 0.1480] | H4-H3: no clear MAE difference; interval spans zero; delta=-0.3642, 95% CI [-0.8167, 0.0681]
ridge / H4_5d	5.754	0.233	6/23	H4-H2: no clear MAE difference; interval spans zero; delta=0.0492, 95% CI [-0.0783, 0.1720] | H4-H3: no clear MAE difference; interval spans zero; delta=-0.0415, 95% CI [-0.3760, 0.2640]
ridge / H4_7d	5.755	0.133	3/26	H4-H2: no clear MAE difference; interval spans zero; delta=-0.0362, 95% CI [-0.1160, 0.0216] | H4-H3: no clear MAE difference; interval spans zero; delta=-0.5283, 95% CI [-1.4015, 0.2363]
hgb / H1_3d	6.497	0.000	0/30	H1-B0: no clear MAE difference; interval spans zero; delta=0.2147, 95% CI [-0.5475, 1.0225]
hgb / H1_5d	6.704	0.000	0/30	H1-B0: no clear MAE difference; interval spans zero; delta=0.4225, 95% CI [-0.4097, 1.3354]
hgb / H1_7d	6.799	0.000	0/30	H1-B0: no clear MAE difference; interval spans zero; delta=0.5172, 95% CI [-0.3352, 1.4699]
hgb / H2_3d	6.344	0.000	0/30	H2-H1: no clear MAE difference; interval spans zero; delta=-0.1525, 95% CI [-0.5475, 0.1729]
hgb / H2_5d	6.713	0.000	0/30	H2-H1: no clear MAE difference; interval spans zero; delta=0.0087, 95% CI [-0.4434, 0.5223]
hgb / H2_7d	6.644	0.000	0/30	H2-H1: no clear MAE difference; interval spans zero; delta=-0.1550, 95% CI [-0.6263, 0.3900]
hgb / H3_3d	6.360	0.033	1/29	H3-H1: no clear MAE difference; interval spans zero; delta=-0.1363, 95% CI [-0.4679, 0.1417]
hgb / H3_5d	6.362	0.000	1/30	H3-H1: lower MAE with pointwise exploratory interval below zero; delta=-0.3420, 95% CI [-0.7188, -0.0234]
hgb / H3_7d	6.653	0.000	0/30	H3-H1: no clear MAE difference; interval spans zero; delta=-0.1456, 95% CI [-0.5027, 0.1539]
hgb / H4_3d	6.221	0.000	0/30	H4-H2: no clear MAE difference; interval spans zero; delta=-0.1231, 95% CI [-0.3520, 0.0842] | H4-H3: no clear MAE difference; interval spans zero; delta=-0.1393, 95% CI [-0.5364, 0.2086]
hgb / H4_5d	6.458	0.000	0/30	H4-H2: no clear MAE difference; interval spans zero; delta=-0.2549, 95% CI [-0.5141, 0.0116] | H4-H3: no clear MAE difference; interval spans zero; delta=0.0958, 95% CI [-0.2375, 0.5129]
hgb / H4_7d	6.387	0.000	0/30	H4-H2: lower MAE with pointwise exploratory interval below zero; delta=-0.2573, 95% CI [-0.4109, -0.1016] | H4-H3: no clear MAE difference; interval spans zero; delta=-0.2667, 95% CI [-0.6972, 0.2289]

Appendix C | quality-policy and uncertainty sensitivity

fire_policy_sensitivity.csv

policy	common_history_rows	used_for_primary_model
value_complete_before_advisory_and_outer_purges	704	False
after_conservative_advisory_before_outer_purges	689	False
primary_with_advisory_and_label_maturity_purges	687	True

learner_robustness.csv

experiment	MAE_ridge	MAE_hgb	delta_hgb_minus_ridge
H1_3d	6.1366	6.4965	0.36
H1_5d	6.2356	6.7043	0.4687
H1_7d	6.5853	6.7991	0.2138
H2_3d	5.7014	6.344	0.6426
H2_5d	5.7051	6.7131	1.008
H2_7d	5.7916	6.6441	0.8525
H3_3d	6.1053	6.3603	0.255
H3_5d	5.7958	6.3624	0.5666
H3_7d	6.2838	6.6535	0.3697
H4_3d	5.7411	6.2209	0.4798
H4_5d	5.7542	6.4581	0.7039
H4_7d	5.7555	6.3868	0.6313

The advisory policy and 14-day interval stay primary. Policy alternatives count coverage only; HGB and 7/28-day intervals do not trigger reselection. All complete interval tables remain in the CSV outputs.

Appendix C | additional figures and interpretation

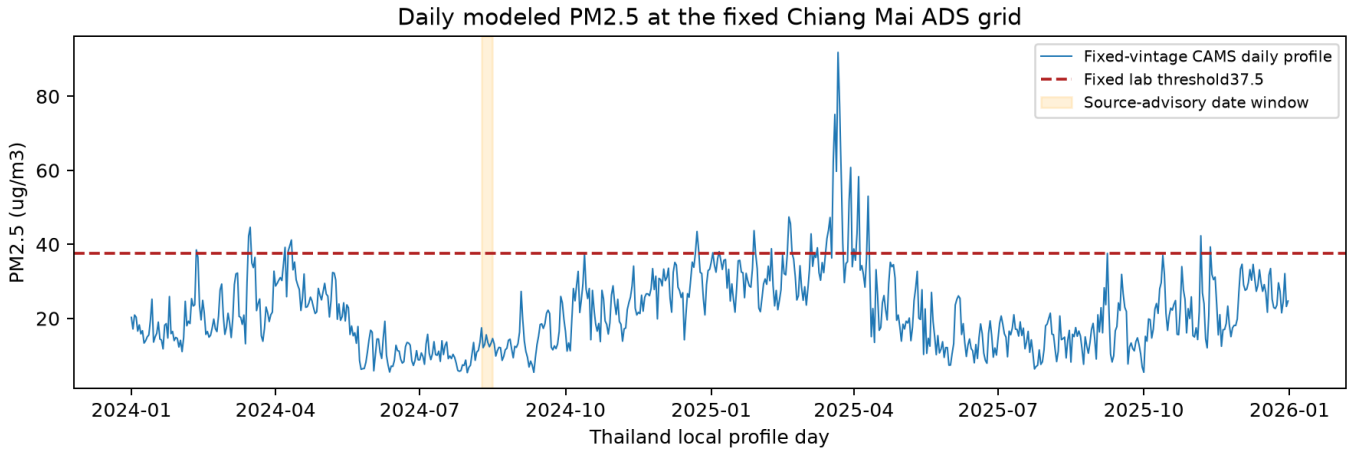


Figure A1. Full-calendar fixed-vintage CAMS profiles; modeled output at one point, not measured provincial exposure.



Figure A2. Source-history availability, conservative advisory policy and maturity purges change cohort coverage.

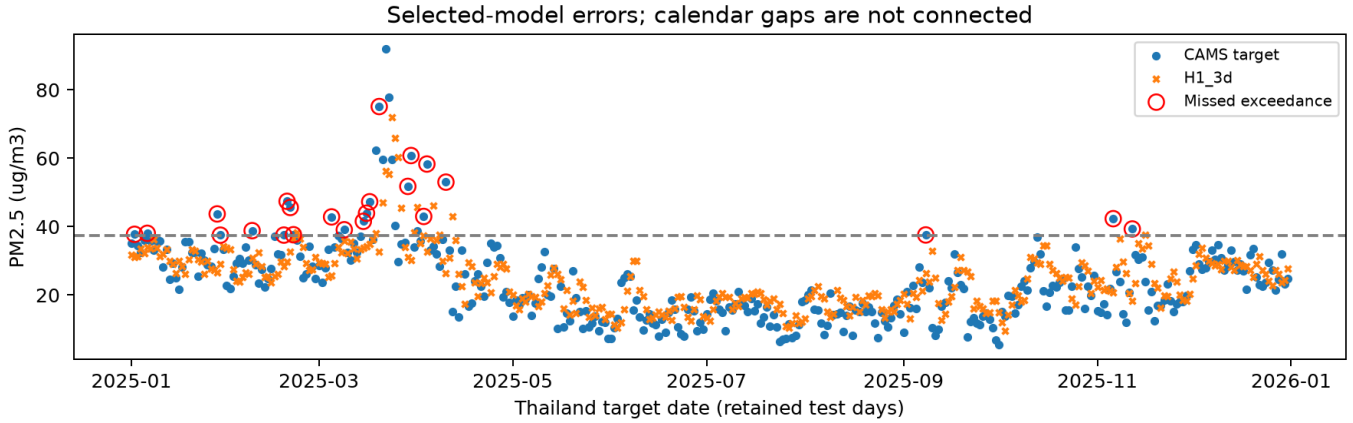


Figure A3. Selected-model forecasts, targets and missed modeled exceedances on retained test dates.

Appendix D | complete executed notebook code cells

English explanations describe each cell. Grey blocks reproduce every code cell with Thai inline comments. Display wrapping is not a source edit. Execution counts reflect the saved notebooks at generation time. The runner rebuilds this PDF after saving all four complete notebooks; final execution evidence is authoritative.

01_fetch_data.ipynb

Cell 3 - Locate the exact project

Variables: ROOT, BASE, PROJECT_NAME: project paths; no scientific inputs.

In [1]

```
from pathlib import Path    กำหนดตำแหน่งโครงการให้ใช้ได้ในเครื่องและ
import sys    ใช้โมดูลของโครงการกับ ทีกำลังรัน
import os    อ่านกุญแจจากสภาพแวดล้อมโดยไม่บันทึกค่า
import json    อ่านค่ากำหนดและข้อมูลอธิบายทีสร้างจริง
import zipfile    ตรวจและแตกแพ็กเกจโครงการเมือจำเป็น
PROJECT_NAME = 'PM25_270702_690631023_Submission'    ระบุชือโครงการฝุนและลำดับงานสีขัน
BASE = Path.cwd().resolve()    ใช้โฟลเดอร์ที กำลังรัน
ROOT = BASE if (BASE / 'config.json').is_file() and (BASE / 'src' / 'workflow.py').is_file() else BASE / PROJE
CT_NAME    เลือกโครงการทีแตกไฟล์ไว้ก่อน
if not (ROOT / 'src' / 'workflow.py').is_file():    ค้นหาแพ็กเกจเมือเปิด เดียวใน
    if not Path('/content').is_dir():    การรันในเครืองต้องมีโครงการทีแตก อยู่ข้าง
        raise FileNotFoundError('Extract the supplied project ZIP and open its notebook first.')
หยุดแทนการนำเข้าโค้ดคนละโครงการ
    from google.colab import files    ขอแพ็กเกจโค้ดและข้อมูลทีมาพร้อม
    uploaded = files.upload()    อัปโหลด โครงการทีมีข้อมูลและโค้ดครบ
    archives = [name for name in uploaded if name.lower().endswith('.zip')]    รับเฉพาะแพ็กเกจ
    assert len(archives) == 1, 'Upload exactly one project ZIP.'    หยุดเมือเลือกแพ็กเกจได้ไม่แน่นอน
    with zipfile.ZipFile(BASE / archives[0]) as archive:    เปิด ทีเลือกเพือตรวจความสมบูรณ์
        assert archive.testzip() is None, 'Project ZIP is damaged.'    ตรวจความสมบูรณ์ ก่อนแตกไฟล์
        for member in archive.infolist():    ตรวจปลายทางทุกไฟล์แทนการเชือชือใน
            destination = (BASE / member.filename).resolve()    หาตำแหน่งปลายทางแบบสมบูรณ์ของทุกไฟล์
            assert destination.is_relative_to(BASE), 'Unsafe archive member.'
ปฏิเสธตำแหน่งไฟล์ทีออกนอกโฟลเดอร์ทำงาน
        archive.extractall(BASE)    แตกไฟล์โครงการหลังตรวจความปลอดภัย
assert (ROOT / 'src' / 'workflow.py').is_file(), 'Expected PM2.5 project not found.'    ตรวจว่ามีโมดูลของโครงการนีจริง
sys.path.insert(0, str(ROOT / 'src'))    ใช้โมดูลต้นฉบับทีแนบมากับโครงการ
print('PROJECT:', ROOT)    แสดงโครงการทีจะรัน
```

Cell 5 - Check environment and record run identity

Variables: CONFIG: fixed configuration; MODE: captured-data replay; run_state: current source/config hashes.

In [2]

```
import importlib.util    ตรวจไลบรารีทีขาดก่อนนำเข้าโมดูลวิเคราะห์
import subprocess    ติดตังแพ็กเกจด้วย ของ เมือจำเป็น
REQUIRED_IMPORTS = ['numpy', 'pandas', 'requests', 'matplotlib', 'scipy', 'sklearn', 'nbformat', 'nbclient', '
reportlab', 'pypdf', 'PIL', 'eccodes']    ระบุไลบรารีทีต้องใช้
missing_imports = [name for name in REQUIRED_IMPORTS if importlib.util.find_spec(name) is None]
ตรวจไลบรารีโดยไม่เปลียนแพ็กเกจทีติดตังเงียบ ๆ
if missing_imports:    ติดตังตามรายการรุ่นเมือขาดไลบรารีทีจำเป็น
    subprocess.check_call([sys.executable, '-m', 'pip', 'install', '-r', str(ROOT / 'requirements.txt')])
ใช้รุ่นแพ็กเกจทีกำหนดเพือให้ทำซ้าได้
FETCH_NEW_WEATHER = False    เปิดเฉพาะเมือต้องการเก็บคำตอบ ชุดใหม่แยกจากชุดทดลองเดิม
MODE = 'replay'    ตรวจและใช้ไฟล์ จริงทีเก็บไว้ตามแผนทีล็อก
os.environ['MPLBACKEND'] = 'Agg'    บันทึกกราฟโดยไม่ต้องใช้หน้าต่างแสดงภาพ
```

Cell 5 - Check environment and record run identity (continued)

Variables: CONFIG: fixed configuration; MODE: captured-data replay; run_state: current source/config hashes.

In [2]

```
for thread_variable in ['OMP_NUM_THREADS', 'OPENBLAS_NUM_THREADS', 'MKL_NUM_THREADS']:
จำกัดเธรดเพื่อให้โมเดลขนาดเล็กทำซ้ำได้
    os.environ.setdefault(thread_variable, '1')    เคารพค่าที่ผู้ใช้ตั้งและให้ค่าเริ่มต้นที่ย้ายเครื่องได้
from common import load_config    อ่านตำแหน่งโครงการและค่าการศึกษาที่กำหนด
os.chdir(ROOT)    ให้  และสคริปต์อ้างอิงโฟลเดอร์โครงการเดียวกัน
ROOT, CONFIG = load_config()    สร้างโฟลเดอร์ผลลัพธ์และอ่านค่ากำหนดการศึกษา
assert CONFIG['study_contract'] == 'next_day_0700_thai', 'Wrong forecast contract.'
ตรวจว่ากำลังใช้ข้อกำหนดเวลาทำนายที่กำหนด
from IPython.display import display, Image, HTML    แสดงตารางหลักฐานและภาพผลการวิเคราะห์
import pandas as pd    อ่านข้อมูลรายวันและตารางผลลัพธ์
import numpy as np    ใช้ตรวจตัวเลขแบบทำซ้ำได้
import workflow as lab    ใช้ฟังก์ชันควบคุม ตรวจ และจัดแพ็กเกจของโครงการ
run_state = lab.begin_run(ROOT, CONFIG, MODE)    บันทึก  โค้ดปัจจุบันก่อนเริ่มวิเคราะห์
display(pd.read_csv(ROOT / 'configuration_dictionary.csv'))    อธิบายค่ากำหนดทุกตัวและเหตุผลที่ใช้
from environment_check import check_environment    ตรวจรุ่นที่ติดตั้งกับรายการที่แนบ
dependency_evidence = check_environment(ROOT, strict=True)    หยุดเมื่อรุ่นแพ็กเกจไม่ตรงแทนการอ้างว่าทำซ้ำได้
print('DEPENDENCIES:', dependency_evidence['status'])    แสดงผลตรวจสภาพแวดล้อมจริง
display(HTML("<style>.jp-CodeCell .jp-InputArea-editor,.input_area{background:#f2f2f2!important;border:1px sol
id #ccc}</style>"))    แสดงพื้นเซลล์โค้ดสีเทาในหน้าที่รองรับ
```

Cell 7 - Inspect the pre-fit source/target contract

Variables: analysis_plan: H1-H4; revision9_contract: issue, source days, selection and evidence limits.

In [3]

```
analysis_plan = json.loads((ROOT / 'analysis_plan.json').read_text(encoding='utf-8'))
อ่านแผนที่ล็อกก่อนมีคะแนนรอบใหม่
display(pd.DataFrame(analysis_plan['hypotheses'].items(), columns=['Group', 'Question']))    แสดงคำถามทั้งสี่กลุ่ม
display(pd.DataFrame(json.loads((ROOT / 'report/study_metadata/study_contract.json').read_text(encoding='utf-8
')).items(), columns=['Contract item', 'Meaning']))    แยกขอบเขตย้อนหลังจากการรับรองพร้อมใช้จริง
```

Cell 9 - Decode and verify every preserved source request

Variables: raw_folder/raw_manifest: immutable captured inputs; station_reference: separate C6 snapshot.

In [4]

```
from weather_acquisition import acquire_weather    ใช้ตัวดึงอากาศจริงชุดเดียวกับสคริปต์
if FETCH_NEW_WEATHER:    เปิดเฉพาะเมื่อต้องการเก็บข้อมูลใหม่แยกจากชุดทดลองเดิม
    display(acquire_weather(ROOT, ROOT / 'data/raw/weather_new_capture'))    เก็บคำตอบ  และหลักฐานจริงไว้แยกชุด
raw_folder, raw_manifest, station_reference = lab.acquire_all(ROOT, CONFIG, mode=MODE)    ตรวจ  จริงและสร้าง
 ใหม่จากข้อมูลดิบ
print('RAW RUN:', raw_manifest['run_id'], '| Preserved files:', len(raw_manifest['files']))
แสดงรอบข้อมูลโดยไม่เปิดเผย
display(pd.DataFrame(json.loads((ROOT / 'outputs/results/raw_decode_audit.json').read_text(encoding='utf-8'))[
'records']))    ตรวจจำนวน  และ  ของคำขอทั้ง
```

Cell 11 - Inspect provenance and scoped station evidence

Variables: source_inventory: payload inventory; C6 table: contemporary rolling-24h comparison.

In [5]

```
source_inventory = pd.DataFrame(raw_manifest['files'])    อ่านรายการไฟล์จริงและ  ใน
display(source_inventory[['file', 'bytes', 'status']].head(12))    ตัวอย่างรายการ โดยไฟล์ครบอยู่ใน
display(pd.read_csv(ROOT / 'outputs/results/station_crosscheck.csv'))    แสดงการเทียบสถานีที่เก็บไว้ตามเวลาและหน่วยจริง
```

Cell 13 - Run raw checkpoint and show source clocks

Variables: raw_validation: technical checks; source contract: nominal timing, not observed release records.

In [6]

```
from check_dataset import check_raw, require_pass   ใช้ ชุดเดียวกับสคริปต์
raw_validation = require_pass(check_raw(ROOT, CONFIG))   หยุดเมื่อหลักฐาน หรือ เปลี่ยน
display(pd.DataFrame(raw_validation['checks']))   แสดงทั้งข้อที่ผ่านและข้อที่ยังไม่รับรอง
display(pd.DataFrame(json.loads((ROOT / 'outputs/results/source_time_contract.json').read_text(encoding='utf-8
'))['sources']))   แสดงนาฬิกาของแต่ละแหล่งอย่างชัดเจน
```

02_prepare_data.ipynb

Cell 3 - Locate the exact project

Variables: ROOT, BASE, PROJECT_NAME: project paths; no scientific inputs.

In [1]

```
from pathlib import Path   กำหนดตำแหน่งโครงการให้ใช้ได้ในเครื่องและ
import sys   ใช้โมดูลของโครงการกับ ทีกำลังรัน
import os   อ่านกุญแจจากสภาพแวดล้อมโดยไม่บันทึกค่า
import json   อ่านค่ากำหนดและข้อมูลอธิบายที่สร้างจริง
import zipfile   ตรวจและแตกแพ็กเกจโครงการเมือจำเป็น
PROJECT_NAME = 'PM25_270702_690631023_Submission'   ระบุชื่อโครงการฝุ่นและลำดับงานสีข้น
BASE = Path.cwd().resolve()   ใช้โฟลเดอร์ที กำลังรัน
ROOT = BASE if (BASE / 'config.json').is_file() and (BASE / 'src' / 'workflow.py').is_file() else BASE / PROJE
CT_NAME   เลือกโครงการทีแตกไฟล์ไว้ก่อน
if not (ROOT / 'src' / 'workflow.py').is_file():   ค้นหาแพ็กเกจเมือเปิด เดียวใน
    if not Path('/content').is_dir():   การรันในเครื่องต้องมีโครงการทีแตก อยู่ข้าง
        raise FileNotFoundError('Extract the supplied project ZIP and open its notebook first.')
หยุดแทนการนำเข้าโค้ดคนละโครงการ
    from google.colab import files   ขอแพ็กเกจโค้ดและข้อมูลทีมาพร้อม
    uploaded = files.upload()   อัปโหลด โครงการทีมีข้อมูลและโค้ดครบ
    archives = [name for name in uploaded if name.lower().endswith('.zip')]   รับเฉพาะแพ็กเกจ
    assert len(archives) == 1, 'Upload exactly one project ZIP.'   หยุดเมือเลือกแพ็กเกจได้ไม่แน่นอน
    with zipfile.ZipFile(BASE / archives[0]) as archive:   เปิด ทีเลือกเพือตรวจความสมบูรณ์
        assert archive.testzip() is None, 'Project ZIP is damaged.'   ตรวจความสมบูรณ์ ก่อนแตกไฟล์
        for member in archive.infolist():   ตรวจปลายทางทุกไฟล์แทนการเชือชือใน
            destination = (BASE / member.filename).resolve()   หาตำแหน่งปลายทางแบบสมบูรณ์ของทุกไฟล์
            assert destination.is_relative_to(BASE), 'Unsafe archive member.'
ปฏิเสธตำแหน่งไฟล์ทีออกนอกโฟลเดอร์ทำงาน
        archive.extractall(BASE)   แตกไฟล์โครงการหลังตรวจความปลอดภัย
assert (ROOT / 'src' / 'workflow.py').is_file(), 'Expected PM2.5 project not found.'   ตรวจว่ามีโมดูลของโครงการนีจริง
sys.path.insert(0, str(ROOT / 'src'))   ใช้โมดูลต้นฉบับทีแนบมากับโครงการ
print('PROJECT:', ROOT)   แสดงโครงการทีจะรัน สร้างไฟล์กราฟโดยไม่เปิดหน้าต่าง
for thread_variable in ['OMP_NUM_THREADS', 'OPENBLAS_NUM_THREADS', 'MKL_NUM_THREADS']:
จำกัดเธรดก่อนนำเข้าไลบรารีคำนวณ
    os.environ.setdefault(thread_variable, '1')   ใช้ค่าเริ่มต้นทีทำซ้ำได้
os.chdir(ROOT)   ให้ทุกพาธอ้างโครงการเดียวกัน
from common import load_config   อ่าน รุ่นนี
ROOT, CONFIG = load_config()   ตรวจเวลาออกคำทำนายและรุ่นโครงการ
from IPython.display import display, Image, HTML   แสดงหลักฐานและรูปภาพทีสร้างจริง
import pandas as pd   อ่านตารางโดยรักษาบทบาทของข้อมูล
import numpy as np   ตรวจค่าตัวเลขและลำดับเวลา
import workflow as lab   ใช้ เดียวกับสคริปต์
from environment_check import check_environment   ตรวจ ทีล็อกรุ่น
dependency_evidence = check_environment(ROOT, strict=True)   ไม่เปลียนรุ่นเงียบ ๆ
display(HTML("<style>.jp-CodeCell .jp-InputArea-editor,.input_area{background:#f2f2f2!important;border:1px sol
id #ccc}</style>"))   รักษาพืนเซลล์โค้ดสีเทา
```

Cell 5 - Construct source-aware daily tables

Variables: daily: full anchored calendar; join_audit: one-to-one join and no-fill accounting.

In [2]

```
from prepare_data import prepare_daily, build_experiments   ใช้การเตรียมข้อมูลเดียวกับสคริปต์
daily, join_audit = prepare_daily(ROOT, CONFIG)   เก็บทุกวัน รวม และ เดิม
display(daily[['date', 'issue_date', 'forecast_origin_utc', 'fire_source_day_utc', 'target_date', 'pm25_tomorrow']].head(10))   ตรวจ ก่อนสร้าง
print(json.dumps(join_audit, indent=2))   แสดงจำนวนแถวก่อนและหลัง
```

Cell 7 - Create source/window features

Variables: X: calendar-lag inputs; specifications: exact 12 sets; eligible: common dates after quality/maturity rules.

In [3]

```
X, specifications, eligible = build_experiments(ROOT, CONFIG, daily)   สร้าง กลุ่ม หน้าต่างบนวันเดียวกัน
display(pd.DataFrame([{k: v for k, v in item.items() if k != 'features'} for item in specifications]))   แสดง และจำนวนตัวแปร
display(pd.read_csv(ROOT / 'outputs/results/feature_manifest.csv'))   นิยามตัวแปร หน่วย เหตุผล และ ทุกตัว
print('COMMON ELIGIBLE DAYS:', int(eligible.sum()))   ไม่นับกริดหรือ ซ้ำเป็นจำนวนวัน
```

Cell 9 - Check missingness, source clocks and exact cohort

Variables: dataset_validation: current checker proof; missing_decisions/cohort_ledger: explicit fill/drop rationale.

In [4]

```
from check_dataset import check_dataset, require_pass   ตรวจความถูกต้องก่อนส่งเข้าโมเดล
dataset_validation = require_pass(check_dataset(ROOT, CONFIG, daily, X, specifications, eligible))   ตรวจ และขอบ
display(pd.DataFrame(dataset_validation['checks']))   แสดงข้อจำกัด แยกจาก
display(pd.read_csv(ROOT / 'outputs/results/missing_decisions.csv'))   อธิบายทุกคอลัมน์ว่าทำไมไม่ และกรณีใดไม่เข้าโมเดล
display(pd.read_csv(ROOT / 'outputs/results/cohort_ledger.csv'))   บัญชีเหตุผลแบบไม่ซ้ำนับแถว
```

Cell 11 - Export purged partitions and build the audit store

Variables: handoff: shared checker/export/coverage/database outputs; CV audit: fitting cutoffs before validation issues.

In [5]

```
from stages import prepare_handoff   ใช้ เพื่อไม่ให้ และ ต่างกัน
handoff = prepare_handoff(ROOT, CONFIG, daily, X, specifications, eligible)   ตรวจข้อมูล ส่งออก แยก และสร้าง

display(pd.read_csv(ROOT / 'outputs/results/chronology.csv'))   แสดงวันและจำนวนแต่ละ
display(pd.read_csv(ROOT / 'outputs/results/cv_calendar_audit.csv'))   ตรวจ ภายในแต่ละ
print('SQL STORE:', handoff['reference']['status'])   ฐานข้อมูลใช้ตรวจหลักฐานจริง ไม่ใช่สร้าง ใหม่
```

Cell 13 - Inspect coverage before modeling

Variables: row_inclusion: calendar eligibility; feature_availability: nominal vs observed evidence.

In [6]

```
display(pd.read_csv(ROOT / 'outputs/results/row_inclusion.csv').tail(12))   คงแถวที่ไม่ใช้ให้ตรวจเหตุผลได้
display(pd.read_csv(ROOT / 'outputs/results/feature_availability.csv'))   แสดงสถานะ ของ ตามจริง
display(Image(filename=str(ROOT / 'outputs/figures/06_matched_period_coverage.png'), width=900))
แสดงผลการคัดวันร่วมและความเป็นตัวแทน
```

03_analyse.ipynb

Cell 3 - Locate the exact project

Variables: ROOT, BASE, PROJECT_NAME: project paths; no scientific inputs.

In [1]

```
from pathlib import Path    กำหนดตำแหน่งโครงการให้ใช้ได้ในเครื่องและ
import sys    ใช้โมดูลของโครงการกับ ทีกำลังรัน
import os    อ่านกุญแจจากสภาพแวดล้อมโดยไม่บันทึกค่า
import json    อ่านค่ากำหนดและข้อมูลอธิบายทีสร้างจริง
import zipfile    ตรวจและแตกแพ็กเกจโครงการเมือจำเป็น
PROJECT_NAME = 'PM25_270702_690631023_Submission'    ระบุชือโครงการฝุ่นและลำดับงานสีขัน
BASE = Path.cwd().resolve()    ใช้โฟลเดอร์ที กำลังรัน
ROOT = BASE if (BASE / 'config.json').is_file() and (BASE / 'src' / 'workflow.py').is_file() else BASE / PROJE
CT_NAME    เลือกโครงการทีแตกไฟล์ไว้ก่อน
if not (ROOT / 'src' / 'workflow.py').is_file():    ค้นหาแพ็กเกจเมือเปิด เดียวใน
    if not Path('/content').is_dir():    การรันในเครืองต้องมีโครงการทีแตก อยู่ข้าง
        raise FileNotFoundError('Extract the supplied project ZIP and open its notebook first.')
หยุดแทนการนำเข้าโค้ดคนละโครงการ
    from google.colab import files    ขอแพ็กเกจโค้ดและข้อมูลทีมาพร้อม
    uploaded = files.upload()    อัปโหลด โครงการทีมีข้อมูลและโค้ดครบ
    archives = [name for name in uploaded if name.lower().endswith('.zip')]    รับเฉพาะแพ็กเกจ
    assert len(archives) == 1, 'Upload exactly one project ZIP.'    หยุดเมือเลือกแพ็กเกจได้ไม่แน่นอน
    with zipfile.ZipFile(BASE / archives[0]) as archive:    เปิด ทีเลือกเพือตรวจความสมบูรณ์
        assert archive.testzip() is None, 'Project ZIP is damaged.'    ตรวจความสมบูรณ์ ก่อนแตกไฟล์
        for member in archive.infolist():    ตรวจปลายทางทุกไฟล์แทนการเชือชือใน
            destination = (BASE / member.filename).resolve()    หาตำแหน่งปลายทางแบบสมบูรณ์ของทุกไฟล์
            assert destination.is_relative_to(BASE), 'Unsafe archive member.'
ปฏิเสธตำแหน่งไฟล์ทีออกนอกโฟลเดอร์ทำงาน
        archive.extractall(BASE)    แตกไฟล์โครงการหลังตรวจความปลอดภัย
assert (ROOT / 'src' / 'workflow.py').is_file(), 'Expected PM2.5 project not found.'    ตรวจว่ามีโมดูลของโครงการนีจริง
sys.path.insert(0, str(ROOT / 'src'))    ใช้โมดูลต้นฉบับทีแนบมากับโครงการ
print('PROJECT:', ROOT)    แสดงโครงการทีจะรัน สร้างไฟล์กราฟโดยไม่เปิดหน้าต่าง
for thread_variable in ['OMP_NUM_THREADS', 'OPENBLAS_NUM_THREADS', 'MKL_NUM_THREADS']:
จำกัดเธรดก่อนนำเข้าไลบรารีคำนวณ
    os.environ.setdefault(thread_variable, '1')    ใช้ค่าเริมต้นทีทำซ้ำได้
os.chdir(ROOT)    ให้ทุกพาธอ้างโครงการเดียวกัน
from common import load_config    อ่าน รุ่นนี
ROOT, CONFIG = load_config()    ตรวจเวลาออกคำทำนายและรุ่นโครงการ
from IPython.display import display, Image, HTML    แสดงหลักฐานและรูปภาพทีสร้างจริง
import pandas as pd    อ่านตารางโดยรักษาบทบาทของข้อมูล
import numpy as np    ตรวจค่าตัวเลขและลำดับเวลา
import workflow as lab    ใช้ เดียวกับสคริปต์
from environment_check import check_environment    ตรวจ ทีล็อกรุ่น
dependency_evidence = check_environment(ROOT, strict=True)    ไม่เปลียนรุ่นเงียบ ๆ
display(HTML("<style>.jp-CodeCell .jp-InputArea-editor,.input_area{background:#f2f2f2!important;border:1px sol
id #ccc}</style>"))    รักษาพืนเซลล์โค้ดสีเทา
```

Cell 5 - Describe the verified modeled series

Variables: daily: preserved profiles; annual/monthly: descriptive summaries, not station violations.

In [2]

```
daily = lab.load_prepared(ROOT, CONFIG)    ปฏิเสธตารางทีเปลียนหลังเตรียมข้อมูล
from prepare_data import build_experiments    อ่านชุดทดลองตาม เดิม
X, specifications, eligible = build_experiments(ROOT, CONFIG, daily)    ไม่เลือกตัวแปรใหม่จากความสัมพันธ์ใน
```

Cell 5 - Describe the verified modeled series (continued)

Variables: daily: preserved profiles; annual/monthly: descriptive summaries, not station violations.

In [2]

```
import analyse as analysis   ใช้กราฟร่วมกับสคริปต์
annual, monthly = analysis.describe(ROOT, CONFIG, daily)   สรุปความรุนแรงและฤดูกาลในข้อมูลจำลอง
```

Cell 7 - Interpret severity without overclaiming representativeness

Variables: annual/monthly summaries use full available modeled days; calendar denominators are explicit.

In [3]

```
display(annual)   รายงานจำนวนวันจริงและสัดส่วน ไม่เปรียบเทียบจำนวนโดยลืม
display(monthly)   ค่าเฉลี่ยรายเดือนจากสองปี ไม่ใช่การพิสูจน์เหตุและผล
display(Image(filename=str(ROOT / 'outputs/figures/01_daily_pm25.png'), width=900))   แสดงโปรไฟล์และวันที่ต้องระวัง
display(Image(filename=str(ROOT / 'outputs/figures/02_exceedances_seasonality.png'), width=900))
แสดงจำนวนเกินเกณฑ์และฤดูกาล
```

Cell 9 - Inspect fire-source limitations and one-receptor scope

Variables: Spatial evidence and modeled episodes are diagnostic only; no parameter or mask reselection.

In [4]

```
display(Image(filename=str(ROOT / 'outputs/figures/03_fire_quality.png'), width=900))
ตรวจค่าศูนย์ไฟกับการสังเกตแยกกัน
display(pd.DataFrame(json.loads((ROOT / 'outputs/results/spatial_resolution_audit.json').read_text(encoding='u
tf-8')).items(), columns=['Spatial item', 'Evidence']))   แสดงขอบเขตหนึ่งจุดและกริดต้นทาง
display(pd.read_csv(ROOT / 'outputs/results/exceedance_episodes.csv').head(12))
ตัวอย่างเหตุการณ์จำลองต่อเนื่องโดยไม่เปลี่ยนการคัดวัน
```

04_model.ipynb

Cell 3 - Locate the exact project

Variables: ROOT, BASE, PROJECT_NAME: project paths; no scientific inputs.

In [1]

```
from pathlib import Path   กำหนดตำแหน่งโครงการให้ใช้ได้ในเครื่องและ
import sys   ใช้โมดูลของโครงการกับ ทีกำลังรัน
import os   อ่านกุญแจจากสภาพแวดล้อมโดยไม่บันทึกค่า
import json   อ่านค่ากำหนดและข้อมูลอธิบายที่สร้างจริง
import zipfile   ตรวจและแตกแพ็กเกจโครงการเมือจำเป็น
PROJECT_NAME = 'PM25_270702_690631023_Submission'   ระบุชื่อโครงการฝุ่นและลำดับงานสีขั้น
BASE = Path.cwd().resolve()   ใช้โฟลเดอร์ที กำลังรัน
ROOT = BASE if (BASE / 'config.json').is_file() and (BASE / 'src' / 'workflow.py').is_file() else BASE / PROJE
CT_NAME   เลือกโครงการที่แตกไฟล์ไว้ก่อน
if not (ROOT / 'src' / 'workflow.py').is_file():   ค้นหาแพ็กเกจเมือเปิด เดียวใน
    if not Path('/content').is_dir():   การรันในเครื่องต้องมีโครงการที่แตก อยู่ข้าง
        raise FileNotFoundError('Extract the supplied project ZIP and open its notebook first.')
หยุดแทนการนำเข้าโค้ดคนละโครงการ
    from google.colab import files   ขอแพ็กเกจโค้ดและข้อมูลที่มาพร้อม
    uploaded = files.upload()   อัปโหลด โครงการที่มีข้อมูลและโค้ดครบ
    archives = [name for name in uploaded if name.lower().endswith('.zip')]   รับเฉพาะแพ็กเกจ
    assert len(archives) == 1, 'Upload exactly one project ZIP.'   หยุดเมือเลือกแพ็กเกจได้ไม่แน่นอน
    with zipfile.ZipFile(BASE / archives[0]) as archive:   เปิด ที่เลือกเพื่อตรวจความสมบูรณ์
        assert archive.testzip() is None, 'Project ZIP is damaged.'   ตรวจความสมบูรณ์ ก่อนแตกไฟล์
        for member in archive.infolist():   ตรวจปลายทางทุกไฟล์แทนการเชือชือใน
            destination = (BASE / member.filename).resolve()   หาตำแหน่งปลายทางแบบสมบูรณ์ของทุกไฟล์
            assert destination.is_relative_to(BASE), 'Unsafe archive member.'
ปฏิเสธตำแหน่งไฟล์ที่ออกนอกโฟลเดอร์ทำงาน
        archive.extractall(BASE)   แตกไฟล์โครงการหลังตรวจความปลอดภัย
assert (ROOT / 'src' / 'workflow.py').is_file(), 'Expected PM2.5 project not found.'   ตรวจว่ามีโมดูลของโครงการนีจริง
sys.path.insert(0, str(ROOT / 'src'))   ใช้โมดูลต้นฉบับที่แนบมากับโครงการ
print('PROJECT:', ROOT)   แสดงโครงการที่จะรัน สร้างไฟล์กราฟโดยไม่เปิดหน้าต่าง
for thread_variable in ['OMP_NUM_THREADS', 'OPENBLAS_NUM_THREADS', 'MKL_NUM_THREADS']:
จำกัดเธรดก่อนนำเข้าไลบรารีคำนวณ
    os.environ.setdefault(thread_variable, '1')   ใช้ค่าเริ่มต้นที่ทำซ้ำได้
os.chdir(ROOT)   ให้ทุกพาธอ้างโครงการเดียวกัน
from common import load_config   อ่าน รุ่นนี
ROOT, CONFIG = load_config()   ตรวจเวลาออกคำทำนายและรุ่นโครงการ
from IPython.display import display, Image, HTML   แสดงหลักฐานและรูปภาพที่สร้างจริง
import pandas as pd   อ่านตารางโดยรักษาบทบาทของข้อมูล
import numpy as np   ตรวจค่าตัวเลขและลำดับเวลา
import workflow as lab   ใช้ เดียวกับสคริปต์
from environment_check import check_environment   ตรวจ ทีล็อกรุ่น
dependency_evidence = check_environment(ROOT, strict=True)   ไม่เปลียนรุ่นเงียบ ๆ
display(HTML("<style>.jp-CodeCell .jp-InputArea-editor,.input_area{background:#f2f2f2!important;border:1px sol
id #ccc}</style>"))   รักษาพืนเซลล์โค้ดสีเทา
```

Cell 5 - Verify the locked modeling inputs

Variables: X/specifications/eligible: immutable design inputs; Ridge alpha and HGB grid are fixed.

In [2]

```
daily = lab.load_prepared(ROOT, CONFIG)   อ่านตารางที่ตรวจ แล้ว
from prepare_data import build_experiments   รักษาคำถาม แบบเดิม
X, specifications, eligible = build_experiments(ROOT, CONFIG, daily)   ใช้ - และ
```

Cell 5 - Verify the locked modeling inputs (continued)

Variables: X/specifications/eligible: immutable design inputs; Ridge alpha and HGB grid are fixed.

In [2]

```
from check_dataset import check_dataset, require_pass   ใช้ ชุดเดียวกับ
require_pass(check_dataset(ROOT, CONFIG, daily, X, specifications, eligible))   ไม่ฝึกต่อหาก หรือ ผิด
```

Cell 7 - Inspect partition and answer-free interface

Variables: B0: persistence; B1: provider reference; C0: warning-only majority; test_feature_columns: no answer columns.

In [3]

```
from evaluate_forecast import lock_experiment, verify_receipts   จัดการการล็อกและ ของรอบจริง
display(pd.read_csv(ROOT / 'outputs/results/chronology.csv'))   แสดงรอยต่อที่ผ่าน
test_feature_columns = pd.read_csv(ROOT / 'data/processed/evaluation_inputs/test_features.csv', nrows=0).colum
ns.tolist()   อ่านเฉพาะหัวคอลัมน์ ของ
assert not {'y_true', 'pm25_tomorrow', 'exceed_tomorrow'} & set(test_feature_columns)   ไม่ให้คำตอบเป็นคอลัมน์ทำนาย
print('Answer-free test columns:', len(test_feature_columns))   นับ โดยไม่เปิดคำตอบ
```

Cell 9 - Fit and lock without test-label selection

Variables: forecast_plan: frozen source/data/model identities; tuning: training-CV and validation results.

In [4]

```
forecast_plan = lock_experiment(ROOT, CONFIG)   ฝึกจาก เลือกจาก และล็อก ปัจจุบัน
display(pd.DataFrame(json.loads((ROOT / 'outputs/results/tuning.json').read_text(encoding='utf-8'))))
รายงานพารามิเตอร์ทุกแบบ
print('VALIDATION-SELECTED:', forecast_plan['selection'])   ไม่เลือกผู้ชนะใหม่จาก
```

Cell 11 - Commit forecasts before scoring

Variables: prediction_receipt: current lock/prediction hash; sql_commitment: answer-free database write.

In [5]

```
from stages import commit_predictions   ใช้ขั้นทำนายและ ร่วมกับสคริปต์
prediction_receipt, sql_commitment = commit_predictions(ROOT)   ไม่ส่ง ของช่วง เข้า
print(json.dumps(prediction_receipt, indent=2))   เก็บรหัสรอบ เวลา และ ของคำทำนาย
print('SQL COMMITMENT:', sql_commitment)   ตรวจว่าบันทึกคำทำนายก่อนเปิดคำตอบ
```

Cell 13 - Check committed coverage before reading answers

Variables: committed: predictions and identity keys; no test outcomes.

In [6]

```
committed = pd.read_csv(ROOT / 'outputs/results/predictions_test_blind.csv')   อ่านคำทำนายที แล้วเท่านั้น
assert 'y_true' not in committed and not committed.isna().any().any()   ตรวจว่าไม่มีคำตอบหรือคำทำนายขาด
display(committed.head())   ตัวอย่างผลที่ยังไม่รวมคำตอบ
print('Committed test dates:', len(committed))   ทุกแบบต้องมีจำนวนวันเท่ากัน
```

Cell 15 - Evaluate all locked settings on matched dates

Variables: scores: MAE/RMSE/warning metrics; comparisons: paired uncertainty; diagnostic_evidence: fixed secondary analyses.

In [7]

```
from stages import score_and_diagnose   ใช้ขั้นประเมินแยกจากขั้น
scores, comparisons, diagnostic_evidence = score_and_diagnose(ROOT, CONFIG)   เปิดคำตอบหลังตรวจ
และคำนวณทุกแบบ
display(scores.query('partition == "test" and family == "baseline"'))   รายงาน ก่อนโมเดล
print('RECEIPTS:', verify_receipts(ROOT)['status'])   ยืนยันลำดับ - - ของรอบปัจจุบัน
```

Cell 17 - Display all primary results without reselection

Variables: mae_matrix and test score rows are descriptive; validation selection stays frozen.

In [8]

```
import analyse as analysis   ใช้กราฟจาก ทีบันทึกจริง
mae_matrix = analysis.model_figures(ROOT, CONFIG, scores)   สร้าง และกราฟ
display(mae_matrix)   เทียบทุกกลุ่มและหน้าต่าง
display(scores.query('partition == "test" and family == "ridge"'))   ไม่ซ่อนแบบทีทำนายแย่กว่า
display(Image(filename=str(ROOT / 'outputs/figures/04_twelve_settings.png'), width=850))   ดูผลเปรียบเทียบครบ
แบบ
```

Cell 19 - Answer all twelve questions and conditional additions

Variables: comparisons: exact matched-day deltas; twelve_answers: H1a-H4c; window_selection: validation only.

In [9]

```
display(comparisons.query('family == "ridge"')[['window', 'comparison', 'estimate', 'ci_low', 'ci_high', 'inte
rpretation']])   แสดงทั้งทิศทางและความไม่แน่นอน
display(pd.read_csv(ROOT / 'outputs/results/twelve_answers.csv').query('family == "ridge"'))   ตอบครบ
คำถามย่อยตามหลักฐาน
display(pd.read_csv(ROOT / 'outputs/results/window_selection_by_group.csv').query('family == "ridge"'))
หน้าต่างทีเลือกจาก ไม่ใช่
```

Cell 21 - Inspect failure modes without test-driven changes

Variables: missed_day_details: FN events; learner/block sensitivity: fixed secondary checks.

In [10]

```
display(pd.read_csv(ROOT / 'outputs/results/missed_day_details.csv'))   แสดงทุกวันทีโมเดลพลาดเกินเกณฑ์
display(pd.read_csv(ROOT / 'outputs/results/learner_robustness.csv'))   เปรียบเทียบ รองโดยไม่เลือกใหม่
display(pd.read_csv(ROOT / 'outputs/results/bootstrap_sensitivity.csv').query('family == "ridge"'))
ตรวจความไวต่อความยาว ทีกำหนดไว้
display(Image(filename=str(ROOT / 'outputs/figures/07_warning_days.png'), width=900))
แสดงคำตอบและความผิดพลาดตามวันจริง
```

Cell 23 - Review C4/C6 and the availability gate

Variables: Station/spatial/gate artifacts have distinct scopes; none are hidden model predictors.

In [11]

```
display(pd.read_csv(ROOT / 'outputs/results/station_crosscheck.csv'))   รายงาน แยกจาก
ของโมเดล
print(json.dumps(json.loads((ROOT / 'outputs/results/spatial_resolution_audit.json').read_text(encoding='utf-8
')), indent=2))   ไม่สร้างจุดศึกษาทีสองจากกริดเดียวกัน
print(json.dumps(json.loads((ROOT / 'outputs/results/availability_gate.json').read_text(encoding='utf-8')), in
dent=2))   คงข้อจำกัด และ ตามจริง
```

Cell 25 - Verify and render one consistent report

Variables: report_evidence: science/SQL proof; documents: report/proposal generated from this run.

In [12]

```
from stages import report_ready_artifacts   ใช้รายงานและการตรวจร่วมกับสคริปต์
report_evidence = report_ready_artifacts(ROOT, CONFIG, daily, X, specifications, eligible)   ตรวจ
และสร้าง
from report import build_report   สร้างรายงานจากผลรอบเดียวกัน
documents = build_report(ROOT, CONFIG)   คงรูปแบบเดิมและเปลี่ยนเฉพาะเนื้อหาทีหลักฐานใหม่เกียวข้อง
print('TECHNICAL VERIFICATION:', report_evidence['science']['status'])   ไม่แปลง เป็นการรับรอง

print('DOCUMENTS:', documents)   ตรวจจำนวนหน้าและตำแหน่งจริง
```

Cell 27 - Package current saved evidence

Variables: candidate_zip: current archive; execution_evidence: actual saved outputs, not a promise.

In [13]

```
candidate_zip, execution_evidence = lab.make_submission(ROOT)    ตรวจไฟล์และสร้าง จากสิ่งที่บันทึกจริง
print('CANDIDATE ZIP:', candidate_zip)    ตัวรันจะ ใหม่หลังบันทึกครบทุกเซลล์
print('SAVED EXECUTION EVIDENCE:', execution_evidence)    ไม่ประดิษฐ์ ให้เซลล์ที่ยังไม่บันทึก
```

Cell 29 - Optionally verify real Colab exports

Variables: SEAL_COLAB_EXPORTS: optional user-controlled export check, False for local automated execution.

In [14]

```
SEAL_COLAB_EXPORTS = False    เปิดใช้หลังรันครบและส่งออก จริงทั้งสีไฟล์
if SEAL_COLAB_EXPORTS:    ไม่ให้การรันปกติหยุดรอการโต้ตอบ
    import nbformat    ตรวจต้นฉบับ จำนวนรัน และ ของ จริง
    import re    ยอมให้เปลี่ยนเฉพาะโหมดดึงข้อมูลและค่าจัดแพ็กเกจที่กำหนด
    import tempfile    แยกไฟล์อัปโหลดจากต้นฉบับจนกว่าจะตรวจผ่าน
    from google.colab import files    อัปโหลด ที่ส่งออกจากการันจริงทั้งสีไฟล์
    expected_books = {name: nbformat.read(ROOT / name, as_version=4) for name in lab.NOTEBOOKS}
เก็บต้นฉบับที่คาดหวังก่อนอัปโหลดไฟล์
    previous_directory = Path.cwd()    กลับเข้าโฟลเดอร์โครงการหลังอัปโหลด
    with tempfile.TemporaryDirectory() as upload_folder:    แยกไฟล์อัปโหลดจากพื้นที่ตรวจต้นฉบับ
        try:    คืนโฟลเดอร์ทำงานแม้การอัปโหลดผิดพลาด
            os.chdir(upload_folder)    ป้องกันไฟล์อัปโหลดเขียนทับต้นฉบับก่อนตรวจ
            uploaded_exports = files.upload()    เลือกไฟล์ส่งออกสี ตามชื่อเดิม
        finally:    คืนตำแหน่งทำงานก่อนตรวจหรือจัดแพ็กเกจ
            os.chdir(previous_directory)    กลับเข้าโครงการเดิมที่เซลล์ก่อนหน้าใช้
    assert set(uploaded_exports) == set(lab.NOTEBOOKS), 'Upload exactly the four original notebook filenames.'
   ปฏิเสธหลักฐานการันที่ขาดหรือเกิน
    verified_books = {}    ยังไม่เขียนทับโครงการจนกว่าจะตรวจต้นฉบับและผลครบ
    for name in lab.NOTEBOOKS:    ตรวจทุกชิ้นแทนการเชื่อ หลักเพียงไฟล์เดียว
        incoming = nbformat.reads(uploaded_exports[name].decode('utf-8'), as_version=4)    อ่านเนื้อหา
ที่ส่งออกจริง
        expected = expected_books[name]    ใช้อ้างอิงต้นฉบับที่ป้องกันไว้ก่อนอัปโหลด
        assert len(incoming.cells) == len(expected.cells), 'Notebook structure changed.'
ตรวจให้คำอธิบายและเซลล์วิเคราะห์ตรงต้นฉบับ
        for actual, original in zip(incoming.cells, expected.cells):    เทียบโค้ดและ ทุกเซลล์
            actual_source = re.sub(r"MODE = '(?:live|replay)'", "MODE = '<selected>'", actual.source)
ปรับเฉพาะค่าควบคุมโหมดดึงข้อมูลที่อนุญาต
            original_source = re.sub(r"MODE = '(?:live|replay)'", "MODE = '<selected>'", original.source)
ปรับข้อความควบคุมของต้นฉบับด้วยกฎเดียวกัน
            actual_source = re.sub(r'SEAL_COLAB_EXPORTS = (?:True|False)', 'SEAL_COLAB_EXPORTS = <selected>',
actual_source)    อนุญาตให้เปิดค่าควบคุมการจัดแพ็กเกจ
            original_source = re.sub(r'SEAL_COLAB_EXPORTS = (?:True|False)', 'SEAL_COLAB_EXPORTS = <selected>'
, original_source)    คงการตรวจอักขระส่วนอื่นของต้นฉบับทั้งหมด
            assert actual.cell_type == original.cell_type and actual_source == original_source, 'Export source
 differs from this package.'    ปฏิเสธโค้ดวิเคราะห์ที่ไม่ตรงรุ่น
            if actual.cell_type == 'code':    ตรวจผล จริงรวมเซลล์จัดแพ็กเกจที่ข้ามตามค่าปกติ
                assert actual.execution_count is not None and all(o.output_type != 'error' for o in actual.out
puts), 'Export is incomplete or has errors.'    ไม่สร้างหลักฐานว่าเซลล์รันผ่านขึ้นมาเอง
        verified_books[name] = incoming    เก็บ ที่ตรวจแล้วในหน่วยความจำ
    for name, incoming in verified_books.items():    บันทึกผลรันจริงทั้งชุดหลังตรวจครบ
        nbformat.write(incoming, ROOT / name)    บันทึกต้นฉบับ จำนวนรัน และผลตามไฟล์ที่ส่งออกจริง
    sealed_zip, sealed_evidence = lab.make_submission(ROOT, require_executed=True)    จัดแพ็กเกจฉบับสมบูรณ์เมื่อทุก
บันทึกผลรันแล้ว
```

Cell 29 - Optionally verify real Colab exports (continued)

Variables: SEAL_COLAB_EXPORTS: optional user-controlled export check, False for local automated execution.

In [14]

```
    print('SEALED ZIP:', sealed_zip, '| EVIDENCE:', sealed_evidence)   แสดงหลักฐานรันครบทั้งสี่ไฟล์
    files.download(str(sealed_zip))   ดาวน์โหลดแพ็กเกจโครงการที่ผ่านการตรวจ
else:   ตัวรันในเครื่องจะจัดแพ็กเกจหลังบันทึกทุกขั้น
    print('Optional Colab export sealing skipped; local run_all.py saves and seals automatically.')
อธิบายพฤติกรรมเมื่อใช้ค่าควบคุมเริ่มต้น
```

Appendix E | requirements and source references

Requirement	Where	Evidence / status
C1 local/UTC days	Main p4-5	timezone_examples.csv; rain_interval_audit.csv; source_time_contract.json
C2 joins / row counts	Main p5	join_audit.json; row_inclusion.csv; cohort_ledger.csv
C3 missing / zero / drop	Main p5; Appendix A	missing_decisions.csv; gfas_daily_derived.csv; no target fill
C4 spatial scope	Main p10	One receptor retained; source grids/region explicit
C5 baseline / CV / test	Main p6; p8-9	Persistence+provider reference; maturity-purged CV; all 12 settings
C6 measured reference	Main p10	Preserved separate contemporary Air4Thai/Open-Meteo point check
Section 6.2 knowability	Main p4; p6; p11	Checked source/target offsets, mature labels and fold-local transforms; separate original-release audit not certified
Feasibility checker	Stages01/02	Project-owned check_dataset.py; no additional instructor script
Reproducibility	README; four notebooks	Exact raw payloads, source/data locks, SQL parity and authentic saved cells
Personal submission	Final page	Student review/signature, actual repository access and 10-minute unlisted video remain external

[1] WHO. Ambient (outdoor) air pollution (2024). https://www.who.int/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health . Health context only.

[2] Chansuebsri et al. (2024). Chemical composition and origins of PM2.5 in Chiang Mai (Thailand) by integrated source apportionment and potential source areas. Atmospheric Environment 327,120517. https://doi.org/10.1016/j.atmosenv.2024.120517 . Motivation, not forecast-skill evidence.

[3] ECMWF. CAMS Global atmospheric composition forecast data documentation. https://confluence.ecmwf.int/spaces/CKB/pages/212454117/CAMS+Global+atmospheric+composition+forecast+data+documentation . Native forecast identity, units and nominal release schedule; ADS delay caveat.

[4] ECMWF. GFAS v1.2 data documentation. https://confluence.ecmwf.int/spaces/CKB/pages/88247734/CAMS+global+biomass+burning+emissions+based+on+fire+radiative+power+GFAS+v1.2+data+documentation . UTC means, density, assimilation and offire interpretation.

[5] Open-Meteo. Previous Runs API. https://open-meteo.com/en/docs/previous-runs-api . Forecast values at fixed offsets; not station observations or a per-origin public-release ledger.

[6] PCD/EPO8. Air4Thai PM2.5 rolling-period explanation. https://epo08.pcd.go.th/th/news/detail/180206 . Separate raw station snapshot and boundary sensitivity are preserved.

[7] ECMWF. GFAS/CAMS contamination advisory9-14 August 2024 and corrected GFAS notice. https://forum.ecmwf.int/t/issue-with-gfas-and-cams-global-forecast-outputs-due-to-contaminated-observations/3995 . Conservative date dependencies do not prove local contamination.

[8] scikit-learn. Cross-validation and common pitfalls. https://scikit-learn.org/stable/modules/cross_validation.html ; https://scikit-learn.org/stable/common_pitfalls.html . Fold-local transforms and temporal evaluation.

[9] DS-270702 HW4 PM2.5 lab sheet. Required structure/checkpoints and assessment criteria. Example PDFs inform formatting only.

Scientific counts and metrics come from the delivered raw/processed/result files. Documentation supports nominal contracts; no historical public-release timestamp is invented.

Appendix F | development from the original model

The original notebooks, initial benchmark and current study address related but different questions. The comparison retains the initial results and identifies changes in the evaluation conditions.

Topic	Verified original / retained strength	Development in this study
Original strengths	Temporal evaluation and baseline comparisons were already implemented.	Temporal evaluation and baselines are retained, with fold-local tuning and validation-only selection.
Hypothesis meaning	Original H1-H4 concern upwind-fire gains, total-fire gains, interactions and upwind versus total; original ladder includes PM-only/no-fire references.	H1-H4 now represent four source groups; initial fire-specific hypotheses remain distinct.
History length	The supplied model uses fire lags1-7, PM lag subsets and mixed rolling windows including3/7/14/30 days; it is not a single isolated five-day experiment.	Consecutive 3/5/7-day histories are compared within every source group.
Missing data	Covered-day fire zeros and uncovered-day missing already existed; model pipelines can median-impute remaining predictors. Median imputation is not intrinsically invalid.	A common complete-history cohort supports paired comparisons; no targets or predictors are imputed.
Prediction clock	Valid-date lags alone do not establish source publication at a specified clock time.	The issue is fixed at 07:00 Thai and the target is the following local day. Source offsets follow the declared nominal clocks.
Reproducibility	The original workflow saved metrics, predictions and configurations.	Current source/data/model receipts separate prediction from scoring and verify SQL/CSV/report consistency.
Predictive outcome	Initial results use different feature groups and evaluation conditions; raw MAE cannot isolate an algorithm gain.	Each selected model is compared with its own matched persistence baseline; horizon, sources and cohort changes are explained.

Historical numerical comparison: interpretation first

Stage	N	Selected	Model MAE	Own B0 MAE	Skill vs own B0
Initial benchmark	102	H3_5d	5.720	6.552	+12.7%
Current study	365	H1_3d	6.137	6.282	+2.3%

- The initial benchmark tested a quality-screened 2026 subset; the current study tests full 2025 with a 17h lead to the next local day, explicit archived-vintage targets and different weather/fire products. Raw MAE and event frequency therefore change with evaluation conditions.

- The comparison establishes skill for each model against its own matched persistence reference. It does not identify why every numeric difference occurred or isolate a causal improvement from the algorithm. A controlled accuracy comparison across study designs would require matching target, dates and information sets.

- Structural gains are directly checked: source identities/offsets, forecast-vintage separation, area/unit calculations, mature training labels and consistent notebook/script/SQL/report evidence. Original public release and independent station forecasting remain unresolved.

Evidence: model_development_comparison.csv; reference/initial_benchmark; original_notebook_inventory.json; study_contract.json.

AI disclosure and submission checklist

Final physical page; twelfth main-report page when appendices are excluded. Student review/signature are not supplied by automation.

Where used	Assistance requested	Changes / rejected claims
Data/code	Source-clock design, acquisition/QC and all 12 comparisons.	Preserved real raw payloads; rejected target fill, false-zero conversion and invented publication timestamps.
Analysis	Temporal split, source/window effects and verification.	Retained baselines, validation-only selection and negative/inconclusive results; distinguished modeled targets from measured reference.
Report	English sections, figures, development trace and Thai line comments.	Kept original report style; separated structural progress from predictive outcomes. Student must review and explain submitted work.

[ ] Repository is public or the instructor has access

[x] README explains execution order and dependencies

[x] Raw files are exact captured API responses with hashes

[x] Four notebooks and required scripts are included

[x] Figures and metrics are separate artifacts

[x] Five report sections and all C1-C6 answers are present

[x] Persistence and provider reference are reported alongside the models

[x] Recommendation names a decision-maker and limits

[x] AI disclosure table is supplied for student review

[ ] I personally cloned the published repository and reran it

[ ] I can explain every line and have verified the final disclosure

[ ] The required 10-minute unlisted video and links are submitted

Local technical replay evidence is distinct from a student-verified published-repository clone. The required video demonstrates the report, code and fetch process. Technical PASS does not certify original historical publication, deployment readiness or student understanding.

Student signature: _____ Date: _____